



**VNiVERSiDAD
D SALAMANCA**

CAMPUS DE EXCELENCIA INTERNACIONAL

TRABAJO DE FIN DE GRADO

GRADO EN ESTADÍSTICA

IMPLEMENTACIÓN DE MACHINE LEARNING EN EL BALONCESTO MODERNO NBA.

MACHINE LEARNING IMPLEMENTATION IN MODERN BASKETBALL NBA

SALAMANCA, JULIO 2026

Autor: RAFAEL RODRÍGUEZ PRIETO

Tutor: PEDRO IGNACIO DORADO DÍAZ



**VNiVERSiDAD
D SALAMANCA**

CAMPUS DE EXCELENCIA INTERNACIONAL

TRABAJO DE FIN DE GRADO

GRADO EN ESTADÍSTICA

IMPLEMENTACIÓN DE MACHINE LEARNING EN EL BALONCESTO MODERNO NBA.

MACHINE LEARNING IMPLEMENTATION IN MODERN BASKETBALL NBA

SALAMANCA, JULIO 2026

Autor: RAFAEL RODRÍGUEZ PRIETO

Tutor: PEDRO IGNACIO DORADO DÍAZ

FIRMA DEL AUTOR:

FIRMA DEL TUTOR:

Certificado del tutor de TFG

D. Pedro Ignacio Dorado Díaz, profesor del Departamento de Estadística de la Universidad de Salamanca,

HACE CONSTAR:

Que el trabajo titulado “IMPLEMENTACIÓN DE MACHINE LEARNING EN EL BALONCESTO MODERNO NBA”, que se presenta, ha sido realizado por Rafael Rodríguez Prieto, con DNI ****1299V y constituye la memoria del trabajo realizado para la superación de la asignatura Trabajo de Fin de Grado en Estadística en esta Universidad.

Salamanca, 23 de junio de 2026

Fdo.: Pedro Ignacio Dorado Díaz

ÍNDICE DE CONTENIDOS

1. INTRODUCCIÓN	1
1.1 ESTADO DE LA CUESTIÓN.....	1
1.2 ESTRUCTURA DEL TRABAJO.....	2
1.3 OBJETIVOS	2
2. BALONCESTO, NBA E INFLUENCIA DE LAS ESTADÍSTICAS	3
2.1 BALONCESTO	3
2.1.1 HISTORIA DEL BALONCESTO	3
2.1.2 REGLAS Y CONCEPTOS BÁSICOS	3
2.2 NBA.....	4
2.2.1 HISTORIA.....	4
2.2.2 CONCEPTOS BÁSICOS	5
2.2.3 TEMPORADA REGULAR.....	6
2.2.4 PLAYOFFS	6
2.3 EVOLUCIÓN DE LA MEDIDA Y USO DE LAS ESTADÍSTICAS	7
2.3.1 EVOLUCIÓN DE LAS ESTADÍSTICAS.....	7
2.3.2 INFLUENCIA DE LA ESTADÍSTICA Y EL ANÁLISIS DE DATOS EN LA NBA	8
3. APRENDIZAJE AUTOMÁTICO.....	9
3.1 APRENDIZAJE CONJUNTO	9
3.1.1 BAGGING	10
3.1.2 BOOSTING.....	10
3.1.3 STACKING	11
3.2 MODELOS DE APRENDIZAJE AUTOMÁTICO NO SUPERVISADO	11
3.2.1 CLUSTERING.....	11
3.2.2 CLUSTERING K-MEANS.....	12
3.2.3 ANÁLISIS DE COMPONENTES PRINCIPALES (PCA)	13
3.3 REGRESIONES	13
3.3.1 REGRESIÓN LINEAL	13
3.3.2 REGRESIÓN SEGMENTADA	14
3.3.3 REGRESIÓN LOGÍSTICA BINARIA	15
3.3.4 REGRESIÓN LOGÍSTICA MULTINOMIAL.....	16
3.4 OTROS MODELOS DE APRENDIZAJE AUTOMÁTICO SUPERVISADO	16
3.4.1 K VECINOS MÁS CERCANOS (KNN)	16
3.4.2 MÁQUINAS DE VECTORES DE SOPORTE	17
3.4.3 ÁRBOLES DE DECISIÓN	18
3.4.4 NAIVE BAYES	18

4. VALIDACIÓN Y EVALUACIÓN	19
4.1 VALIDACIÓN	19
4.1.1 TRAIN/TEST SPLIT	19
4.1.2 VALIDACIÓN CRUZADA	20
4.1.3 VALIDACIÓN CRUZADA ANIDADA	20
4.2 MÉTRICAS DE EVALUACIÓN	22
4.2.1 DEFINICIÓN Y FORMALIZACIÓN DE LAS MÉTRICAS DE EVALUACIÓN.....	22
4.2.2 INTERPRETACIÓN DE LAS METRICAS DE EVALUACIÓN	24
5. ANÁLISIS EXPLORATORIO DE LOS DATOS.....	25
5.1 COMPRENSIÓN INICIAL	25
5.2 TRATAMIENTO Y DETECCIÓN DE DATOS FALTANTES Y VALORES ATÍPICOS	25
5.3 ANÁLISIS BIVARIADO DE LAS VARIABLES	26
5.4 SELECCIÓN DE VARIABLES MEDIANTE ANÁLISIS MULTIVARIADO	28
6. CASO PRÁCTICO Y RESULTADOS.....	30
6.1 ESTUDIO DE LA EVOLUCIÓN DE LOS PERFILES DE TIRO.....	30
6.2 PREDICCIÓN DE <i>PLAYOFFS</i> A PARTIR DE LA TEMPORADA REGULAR.	36
7. CONCLUSIONES.....	42
8. BIBLIOGRAFÍA.....	43

ÍNDICE DE ILUSTRACIONES

Ilustración 1: Cuadro de los playoffs de la NBA. / Fuente: nbaplayoffpass (2026).....	7
Ilustración 2: Comparación de las 300 zonas con más tiros en 2004 y 2024. / Fuente: Goldsberry (2024)	8
Ilustración 3: Ejemplo de iteraciones de clustering k-means. Fuente: Yerra (2018)	13
Ilustración 4: Representación visual del train/test split. Fuente: Lau et al. (2023)	20
Ilustración 5: Representación gráfica de la validación cruzada. / Fuente: Irizarry (2019).....	20
Ilustración 6: Diagrama de funcionamiento de validación cruzada anidada/ Fuente: Infanti et al. (2023)	21
Ilustración 7: Ejemplo de matriz de correlaciones con heat map. / Fuente: Kassambara, A. (2024)....	27
Ilustración 8: Evaluación número clústeres caso global. / Fuente: elaboración propia con Python.	31
Ilustración 9: Clústeres obtenidos en el caso global. / Fuente: elaboración propia con Python.	32
Ilustración 10: Evolución de la distribución de jugadores por clúster. / Fuente: elaboración propia con Python.	33
Ilustración 11: Clústeres obtenidos en el caso de aleros y guards. / Fuente: elaboración propia con Python	34
Ilustración 12: Evolución de la distribución por clúster en aleros y guards. / Fuente: elaboración propia con Python.	34
Ilustración 13: Clústeres y evolución de estos obtenidos en el caso de pivots. / Fuente: elaboración propia con Python.	34
Ilustración 14: Regresiones segmentadas. / Fuente: elaboración propia con Python.	35
Ilustración 15: Matriz de correlaciones y tabla de VIF / Fuente: elaboración propia con Python y Word.....	37
Ilustración 16: Estudio de los coeficientes beta según el cruce de las fases. Fuente: elaboración propia con Python.....	38
Ilustración 17: Box plot con el rango de los resultados de cada modelo / Fuente: elaboración propia con Python y Word	39
Ilustración 18: Predicciones realizadas por seres humanos en la temporada 2023-24. / Fuente: ESPN (2024)	41

ÍNDICE DE TABLAS

Tabla 1: Pesos de cada variable en cada componente. / Fuente: elaboración propia con Python y Word.....	31
Tabla 2: Descripción mediante medias ponderadas de cada clúster. / Fuente: elaboración propia con Python y Word.....	32
Tabla 3: Porcentaje de los jugadores de una posición por clúster. / Fuente: elaboración propia con Python y Word.....	33
Tabla 4: Medias ponderadas de los clústeres de guards y aleros. Fuente: elaboración propia con Python y Word.....	34
Tabla 5: Tabla para toma de decisiones de selección de variables. / Fuente: elaboración propia con Python y Word.....	38
Tabla 6: Métricas de evaluación de los modelos. / Fuente: elaboración propia con Python y Word ...	40
Tabla 7: Aciertos, fallos y puntuación personalizada de cada modelo. / Fuente: elaboración propia con Python y Word.....	40

1. INTRODUCCIÓN

1.1 ESTADO DE LA CUESTIÓN

El uso de técnicas estadísticas para análisis de datos ha ganado un papel primordial. Esta expansión trasciende los ámbitos tradicionales de la economía o la medicina, estableciéndose también en el mundo de los deportes.

El análisis estadístico en este campo, originalmente se limitaba a evaluar jugadores propios u ojear posibles fichajes; no obstante, en algunos deportes se han empezado a usar como base para diseñar estrategias matemáticamente superiores. Entre ellos destaca el béisbol, con el conocido caso llamado *Moneyball*.

En estos deportes se ha podido observar un cambio significativo en la forma de jugar en los tiempos recientes. En el caso del baloncesto, expertos como Goldsberry (2019) apuntan al análisis de datos como el principal factor desencadenante de la revolución que ha sufrido el deporte en los últimos 15 años.

Y ya no es solo que el análisis de datos haya cambiado la forma en la que se juega el deporte, sino que también se correlaciona directamente con el éxito de los equipos. En un reciente artículo, Wang et al. (2025) demostraron que cada analista adicional que tenía una franquicia NBA suponía un incremento de 1,25 victorias por temporada. En el mismo artículo también explican cómo, para conseguir el mismo aumento de victorias, una franquicia NBA debería gastar 9,3 millones de dólares en sueldos de jugadores.

La historia de los artículos científicos aplicados a la NBA es bastante escueta. Los primeros artículos empezaron a aparecer en la década de los noventa, eran bastante simples y se podían contar con los dedos de la mano. Uno de estos casos es el de Bhandari et al. (1997), donde explicaban el funcionamiento de su aplicación que permitía ojear jugadores en base a sus estadísticas básicas.

CBS Sports (2023) indica la importancia de la *MIT Sloan Sports Analytics Conference* que, junto al aumento de la calidad de las bases de datos ofrecidas por la NBA, hicieron que, a principios del siglo XXI, se produjese un *boom* de publicaciones científicas. Principalmente, se centraban en dos temas: por un lado, análisis de tiro y toma de decisiones, y por otro, predicción de resultados y estudio de variables significativas en esto.

En este primer caso, los artículos antiguamente solo disponían de datos de intentos y aciertos; sin embargo, las nuevas bases de datos disponían de variables como distancia exacta a canasta o, hasta 2016, si existía un defensor cerca y a qué distancia se encontraba.

Se redactaron artículos que buscaban tratar de predecir la probabilidad de éxito de un tiro en función de ciertas variables, como es el caso de Oughali et al. (2019), llegando a obtener una precisión del 68% mediante el uso de *XGBoost*. McFarlane (2019) es un ejemplo del otro tipo de estudios donde se trata de entender qué decisiones llevan al éxito. En su caso, estudió cómo el estadístico avanzado *ETM* o *end of game time metric*, que mide la capacidad de decisión de un equipo en las fases finales del partido, afectaba a su número de victorias, obteniendo un valor del R^2 ajustado de 0,79.

En cuanto al otro grupo de trabajos, generalmente presentan la misma estructura. Utilizar uno o varios métodos de aprendizaje automático, normalmente, supervisado para predecir el resultado de un partido. Dentro de este campo se encuentra *Ayyildiz (2018)*, quien emplea redes neuronales artificiales sobre los estadísticos básicos. Me gustaría destacar la investigación realizada por He y Choi (2025), en la cual aplican métodos de aprendizaje conjunto, usando como metamodelo un perceptrón multicapa, y obteniendo una precisión excepcional del 84 %, cuando la media en este tipo de artículos se sitúa en torno al 70 %.

1.2 ESTRUCTURA DEL TRABAJO

El trabajo se organiza en siete capítulos. Tras este apartado de introducción, se tratan conceptos del baloncesto, la NBA, la evolución de las estadísticas y su influencia. Posteriormente, se hace el desarrollo teórico necesario, con apartados que explican el aprendizaje automático, la validación y evaluación y finalmente, el análisis exploratorio de datos; seguido del marco práctico compuesto por la explicación de las bases de datos, librerías y metodología empleadas y los resultados obtenidos de estas. Finalmente, se indican las conclusiones del trabajo.

1.3 OBJETIVOS

El presente trabajo tiene principalmente dos objetivos. Realizar un análisis de la evolución del juego en la NBA, centrándose en los perfiles de tiro de los jugadores y el desarrollo de un modelo capaz de predecir los resultados de la fase de *playoffs* de la NBA en base a estadísticas obtenidas única y exclusivamente de la fase regular.

Para ello, se han marcado los siguientes subobjetivos.

- Crear grupos de jugadores en función de su perfil de tiro, describirlos y ver cómo evolucionan.
- Analizar si ha existido algún punto de inflexión que haya dado lugar al baloncesto moderno
- Diseñar diversos modelos de aprendizaje automático que predigan la fase de *playoffs*.
- Evaluar y validar dichos modelos aplicando validación cruzada anidada.

2. BALONCESTO, NBA E INFLUENCIA DE LAS ESTADÍSTICAS

2.1 BALONCESTO

2.1.1 HISTORIA DEL BALONCESTO

El 5 de diciembre de 1891, en Springfield, Massachusetts, James Naismith inventó el baloncesto, o, al menos, una versión primitiva del mismo. Naismith buscaba un deporte que se pudiera jugar en los meses de invierno y, por lo tanto, en interiores, para evitar el frío.

Aquel baloncesto inicial se disputaba con un balón de fútbol y canastas de mimbre; además, no estaba permitido botar el esférico y el tiempo de juego se dividía en dos periodos de quince minutos. Inicialmente, era solo una actividad más para la clase de educación física de la YMCA; sin embargo, gracias al boca a boca, el juego se expandió rápidamente. Una de las causas de su rápida expansión fueron los soldados estadounidenses, que en la Primera Guerra Mundial practicaban baloncesto en las zonas comunes. En el año 1936, en los Juegos Olímpicos de Berlín, se convirtió en un deporte olímpico, categoría que ha mantenido en todas las ediciones posteriores. Diez años después, en 1946, se fundó la NBA.

Desde ese baloncesto primigenio al actual, ha habido una multitud de cambios. El más conocido e influyente consistió en la introducción de la línea de tres puntos. Dicho cambio se aplicó en el año 1979 y, si bien inicialmente no se le otorgó gran relevancia, se ha convertido en la piedra angular de la forma de jugar a este deporte en los niveles más altos.

2.1.2 REGLAS Y CONCEPTOS BÁSICOS

El baloncesto es un deporte de pelota, en el que dos equipos de cinco jugadores se enfrentan con el objetivo de anotar más puntos que el rival hasta que se llega a un tiempo límite. No puede haber empates, por lo que, si se acaba el tiempo sin un ganador, se disputa una prórroga que se repite tantas veces como sea necesario hasta que se determine el vencedor.

Para anotar puntos, un equipo debe encestar un balón de 23 centímetros de diámetro en una canasta suspendida a 3,05 metros de altura y de 45,7 centímetros de diámetro, lanzándolo con las manos. Detrás de la canasta, se encuentra un tablero rectangular de 1,05 metros de largo por 1,80 de ancho. Dicho tablero permite que la pelota rebote para entrar en la canasta y tiene en su interior una subsección también rectangular de 0,59 por 0,45 metros, que sirve como referencia para el tiro.

La pista es simétrica y rectangular, de 28,65 metros de largo y 15,24 de ancho. Existe una línea con forma casi circular a una distancia de 7,24 metros llamada la línea de triple. Cualquier tiro realizado dentro del área delimitada por esta línea tiene un valor de dos puntos; si se efectúa fuera de esta, su valor es de tres puntos. Dentro de la línea de triple, se encuentra un rectángulo de 4,88 por 5,79 conocido como la zona.

Si bien existen ciertas diferencias entre las reglas del baloncesto FIBA y de la NBA, estas no se encuentran en los conceptos básicos. Dado que este trabajo se realiza sobre la NBA, se describen sus reglas más básicas. Según el reglamento de la National Basketball Association (2026), los partidos se dividen en cuatro periodos de doce minutos, denominados cuartos. Hay

un descanso de quince minutos entre el segundo y el tercer cuarto y de cinco entre el resto. En caso de que el balón deje de estar en juego por cualquier motivo, se para el cronómetro. De esta forma, se evitan las interrupciones y pérdidas de tiempo propias de deportes como el fútbol.

En el momento en que un equipo consigue la posesión, se inicia un contador de veinticuatro segundos. Durante los primeros ocho segundos, el equipo atacante debe pasar la pelota al campo contrario y, una vez haya cruzado, no puede volver. En caso de que transcurran los 24 segundos sin que la pelota toque el aro, se acaba la posesión. Si el equipo atacante realiza un lanzamiento, el balón toca el aro y recuperan el rebote, o si el equipo defensor comete una infracción, el cronómetro se reinicia a catorce segundos.

En todo momento debe haber cinco jugadores en la cancha. Los equipos constan de cinco jugadores titulares y diez suplentes. En cualquier momento en el que no esté el balón en juego y se haya notificado al árbitro con anterioridad, se puede parar el partido para realizar cambios. Un mismo jugador puede salir y entrar al campo en repetidas ocasiones.

Cada jugador suele estar especializado en una o dos posiciones. Existen cinco posiciones, una por cada jugador en el campo. Generalmente, se habla de tres grupos: los *guards* formados por el base y el escolta, los aleros o *wings* formados por el alero y el ala-pívot y, finalmente, el pívot o *center*. Sus tareas son:

- *Guards*: históricamente, han sido las posiciones encargadas de distribuir el juego, aunque la revolución del lanzamiento de triple les ha dado una importancia enorme en el ámbito anotador. Suele estar formado por jugadores que tienen una altura y fuerza inferiores en comparación con el resto de las posiciones, pero una velocidad y agilidad superiores.
- *Aleros*: son jugadores equilibrados, tanto en su estilo de juego como en sus características físicas, a los que se les exige ser capaces de realizar todas y cada una de las facetas del juego a un nivel elevado.
- *Pívots*: son los jugadores más fuertes y altos, aunque generalmente mucho menos ágiles. Se les encomienda recoger rebotes y evitar tiros en la zona interior, para proteger el aro. Junto con los bases, es la posición que más ha evolucionado en los últimos años.

Muchos analistas creen que estos roles diferenciados tienen fecha de caducidad. Algunos como South (2025) afirman que ya han desaparecido y describen un concepto llamado baloncesto sin posición, en el que todos los jugadores son versátiles y capaces de realizar la mayoría de las facetas a un nivel elevado.

2.2 NBA

2.2.1 HISTORIA

En el año 1946 se formó la BAA, una liga nacional de baloncesto que se disputaba durante los meses de invierno, coincidiendo con el descanso de la temporada de hockey sobre hielo. Originalmente, esta liga contaba con once equipos, que se ampliaron a doce cuando se fusionó con la NBL en 1949, momento en el que se renombró a *National Basketball Association* o NBA

Durante las siguientes décadas, su popularidad fue *in crescendo*, hasta el punto de que, a finales de la década de los setenta, se fundó la ABA con el objetivo de hacer competencia a la NBA. Dicha liga consiguió una gran popularidad inicialmente, pero tras menos de diez años, desapareció y cuatro de sus equipos se unieron a la NBA.

En los últimos años, la NBA ha visto un éxito exponencial tanto en concepto de ingresos económicos como de nuevos fans. Las valoraciones económicas de las franquicias se han multiplicado; de hecho, se estima el valor de *Los Angeles Lakers*, la franquicia mejor valorada, en alrededor de diez mil millones de dólares. Los contratos televisivos son tres veces mayores que los de la *Premier League*, la liga de fútbol más grande en este aspecto, y los patrocinios, tanto a nivel de equipo como de jugador, manejan cifras muy elevadas.

A nivel internacional, el baloncesto siempre ha sido considerablemente popular, pero últimamente está adquiriendo una gran relevancia global, hasta el punto de que se puede decir que es el deporte con mayor crecimiento actualmente. Uno de los grandes factores es la aparición del mercado chino. Pu (2016) explica cómo, a principios de siglo, la aparición del jugador chino Yao Ming supuso un antes y un después para el baloncesto en el gigante asiático.

De la misma forma, cada vez hay más jugadores extranjeros en la NBA. De hecho, los últimos cinco jugadores premiados con el MVP, solamente uno nació en América, y este no era estadounidense, sino canadiense. La globalización está afectando notablemente a la NBA y estas son solo algunas de sus consecuencias.

2.2.2 CONCEPTOS BÁSICOS

La NBA es la liga de baloncesto profesional más prestigiosa a nivel global. En ella participan 29 equipos estadounidenses y uno canadiense. Los mejores jugadores del mundo se encuentran en esta liga, hasta el punto de que, en numerosas ocasiones, jugadores destacados de la *Euroliga*, considerada la segunda mejor liga del mundo, han fracasado estrepitosamente al dar el salto a la NBA.

Los equipos se dividen en dos conferencias, que a su vez se reparten en tres divisiones, cada una formada por cinco equipos. En la conferencia Oeste se encuentran las divisiones Noroeste, Suroeste y Pacífica; y la conferencia Este queda fraccionada en divisiones Atlántica, Central y Sureste. La temporada se divide en fase regular y *playoffs*. Tras terminar la fase regular, los equipos mejor clasificados de cada conferencia pasan a los *playoffs*, donde se enfrentan hasta que solo queda uno.

La NBA funciona con un modelo muy popular en el deporte estadounidense llamado sistema de franquicias. Los equipos poseen una plaza en la liga y se mantienen en ella de forma independiente a los resultados; no existen ascensos ni descensos. Este controvertido modelo, a cambio de no premiar el rendimiento, promueve la igualdad entre equipos mediante una serie de factores.

El primero de ellos es que no se puede reclutar a jugadores jóvenes de forma independiente. Cada año hay un evento conocido como el *draft* de la NBA en el que los equipos utilizan elecciones del *draft* para seleccionar a los jugadores jóvenes más prometedores que no pertenezcan a la liga. El orden se obtiene en un sorteo llamado Lotería del *Draft*, en la que solo participan los equipos que no hayan pasado a la fase final, y cuanto peor sea la clasificación del equipo, mayor es su probabilidad de conseguir las primeras elecciones. El objetivo de esta

medida es que los fans de los equipos peor clasificados tengan la esperanza de poder elegir al jugador que les lidere a la gloria.

El segundo es que no existe el concepto europeo de fichaje en deportes; es decir, no se puede realizar un desembolso económico a otro equipo para adquirir a un jugador. Dos equipos deben llegar a un acuerdo para intercambiar combinaciones de jugadores y elecciones.

Estas medidas se diseñaron para promover la igualdad de condiciones; sin embargo, esto en la práctica no se cumple. Un tercio de las franquicias actuales no han conseguido levantar nunca el trofeo y 35 de los 79 campeonatos han ido a parar a las vitrinas de *Los Ángeles Lakers* o *Boston Celtics*. Si se añaden a este número los siete campeonatos conseguidos por *Golden State Warriors*, se obtiene que tres franquicias acumulan más de la mitad de los trofeos.

2.2.3 TEMPORADA REGULAR

Esta fase tiene un formato de liga donde cada equipo juega 82 partidos. En algunos casos, como en 2020 y 2021, la temporada regular puede ser acortada a un número inferior de partidos, pero esto solo puede ocurrir por causas de fuerza mayor. Los encuentros para cada equipo se distribuyen de la siguiente manera:

- Cuatro duelos frente a los cuatro rivales de su misma división y contra algunos rivales de su conferencia.
- Tres partidos contra el resto de los equipos de su misma conferencia.
- Dos encuentros frente a cada equipo de la conferencia opuesta.

La temporada regular suele durar aproximadamente seis meses, entre los meses de octubre y abril, con una pausa de dos semanas en febrero conocida como la pausa del *All-Star*. También en febrero, se marca la fecha límite de intercambios, por lo que algunos analistas suelen decir que la parte final de la temporada es un preludio de los *playoffs*. Una vez todos los equipos han jugado los 82 partidos, los ocho primeros clasificados de cada conferencia pasan a *playoffs* y los siete últimos quedan eliminados y entran en la Lotería del *Draft*.

2.2.4 PLAYOFFS

Los *playoffs* son la fase final de la NBA. Consisten en un cuadro estilo copa de eliminación directa, en el que los equipos quedan emparejados en función de su desempeño en la fase de liga. Para ello, se les asigna un *seeding*, o ranking de su temporada regular respecto a los equipos de su conferencia. La fase de *playoffs* consta de cuartos de final, semifinales y finales de conferencia y las finales de la NBA, conocidas como la gran final, en las cuales el vencedor se corona campeón y los jugadores reciben los anillos de la NBA.

Se divide a los equipos por conferencia y dentro del cuadro de cada conferencia, en la primera fase, los equipos con mejor *seeding* se enfrentan a los peores y se evita que los dos equipos con mejor *seeding* jueguen hasta la final de conferencia.

Todas las series se juegan en un formato al mejor de siete, es decir, el primer equipo en conseguir ganar cuatro partidos avanza a la siguiente fase. A su vez, el equipo de la serie con mayor número de victorias en la temporada regular tiene ventaja de campo. Gracias a esto, se juegan los dos primeros partidos de la serie en su pista y, en caso de que se llegue al séptimo

partido, también juega de local. Históricamente, esto ha dado gran ventaja al equipo que empieza jugando de local, hasta el punto de que Pat Riley en 1983 dijo la famosa frase “ninguna serie de *playoffs* comienza hasta que el equipo visitante gana un partido”, la cual se convirtió en un dicho que sigue utilizándose hoy en día.



Ilustración 1: Cuadro de los playoffs de la NBA. / Fuente: nbaplayoffpass (2026)

2.3 EVOLUCIÓN DE LA MEDIDA Y USO DE LAS ESTADÍSTICAS

2.3.1 EVOLUCIÓN DE LAS ESTADÍSTICAS

En los inicios de la NBA, con el fin de evitar que los aficionados que no podían escuchar los partidos en la radio perdieran el interés, se creó el *box score*. En esta tabla se indicaba primero el resultado del partido, para posteriormente indicar los puntos, intentos de tiro y tiros encestados de cada jugador. En la actualidad, el *box score* original de jugadores presenta muchas más variables y existe uno complementario con datos de todo el equipo. Poco a poco, se fueron añadiendo más variables con la única condición de que fueran fácilmente medibles.

No solo ha evolucionado el *box score*, sino que también se ha profesionalizado la forma de medir estas estadísticas. Antiguamente, había un empleado del equipo local que se encargaba de anotar todos los sucesos del partido. Debido a esto, era bastante común que los datos no fueran precisos. Existe, por ejemplo, el caso de Hakeem Olajuwon, que en la temporada 1989-90 promediaba el doble de tapones jugando de local que de visitante. Años después, algunos empleados admitieron que se inflaban estadísticas secundarias como tapones o asistencias a las estrellas locales.

Actualmente, se utiliza un sistema de seis cámaras similares al Ojo de Halcón del tenis, gestionado por una empresa independiente para asegurar imparcialidad, lo que permite obtener datos más fiables y como se mencionó anteriormente, influyó en la expansión del análisis estadístico.

Con el paso del tiempo, se fueron creando nuevas métricas mediante la combinación o estandarización de las variables de las que se disponía. Los primeros ejemplos son los llamados estadísticos por 36, que ajustaban las estadísticas de los jugadores para simular las que hubieran obtenido si hubieran jugado 36 minutos. También se creó el porcentaje de tiro real, que servía para reflejar mejor la eficiencia de un jugador en las tres formas de anotar (triples, tiros de dos y tiros libres); o las medidas de *rating* ofensivo y defensivo, que indican la cantidad de puntos que se anotan o encajan cada 100 posesiones. Los estadísticos eran simples pero útiles e intuitivos; cualquier fanático podía entender qué eran y cómo funcionaban.

En los últimos años, se han creado estadísticos de una complejidad muy superior a los anteriormente mencionados. El aficionado medio desconoce su existencia, pero son vitales

para los departamentos de análisis de datos, ya sea para analizar el rendimiento de jugadores propios, evaluar si merece la pena incorporar a un jugador rival y, en tal caso, determinar la máxima cantidad de recursos que merecería la pena intercambiar.

2.3.2 INFLUENCIA DE LA ESTADÍSTICA Y EL ANÁLISIS DE DATOS EN LA NBA

Es imposible explicar la influencia de la estadística en la NBA sin usar el caso de los tiros de tres; no obstante, antes merece la pena destacar dos aspectos. El primero de ellos es que, desde que la NBA pasó a utilizar datos obtenidos por una empresa independiente mediante el sistema de cámaras, el número de estudios ha tenido un crecimiento exponencial. Antes de esto, apenas se contaba con datos de calidad, tanto a nivel de precisión como a nivel de variables. De hecho, prácticamente todos los artículos modernos no relacionados con la variable tiro, la cual quedaba recogida en el *box score*, usan siempre datos a partir de la temporada 2009-10 o 2010-11.

El segundo de ellos es la figura de Daryl Morey, gerente general de los *Houston Rockets*. No solo fue pionero en la aplicación del análisis de datos, sino que fue un factor fundamental en que fuera acogido por todas las franquicias. En 2006, fundó la *MIT Sloan Sports Analytics Conference*, donde tanto estudiantes del MIT como investigadores externos exponen investigaciones sobre deporte. Fue el directivo que mejor supo prever la revolución de los tiros de tres. Apostó por crear un sistema donde todos los jugadores eran capaces de encestar triples con una eficiencia mayor que la media. A cambio, sacrificó altura, lo que hacía que tanto la defensa como la capacidad reboteadora empeoraran. Se denominó a este sistema *small ball*.

Tristemente, esta historia no tiene final feliz para Morey. En la temporada 2017-18, los *Houston Rockets* fueron capaces de forzar un séptimo partido en las finales de conferencia contra *Golden State Warriors*. Irónicamente, en ese partido, los *Rockets* fallaron 27 triples seguidos, lo que les hizo pasar de ganar por catorce puntos a perder por diez, sellando su derrota.

Muchos expertos teorizaron que, tras el fracaso de los *Rockets*, la importancia de los triples descendería hasta volver a los niveles de los años 2000. Nada más lejos de la realidad, puesto que año tras año ha ido aumentando el número de triples intentados, hasta estabilizarse en las últimas tres temporadas, con valores aproximadamente dos veces superiores a los de la temporada 2010-11 y un 25 % mayores que los de la temporada 2017-18.

Si bien Morey no consiguió guiar a su equipo hacia un campeonato, sí que marcó un precedente que el resto de los equipos decidieron seguir. Además de aumentar la reputación del análisis de datos aplicado tácticamente, también confirmó las dos bases que en estos momentos siguen rigiendo la forma en la que un equipo consigue un ataque eficaz. Estas son que un equipo debe tener un ataque equilibrado sin depender excesivamente de un tipo de tiro; y que se deben priorizar los tiros cerca del aro y de tres puntos, ya que maximizan los puntos por tiro.




Ilustración 2: Comparación de las 300 zonas con más tiros en 2004 y 2024. / Fuente: Goldsberry (2024)

3. APRENDIZAJE AUTOMÁTICO

El aprendizaje automático es el campo de estudio que da a los ordenadores la capacidad de aprender de forma independiente. En el ámbito estadístico, lo que se entrena no son ordenadores, sino modelos matemáticos que, entre otras cosas, permiten predecir, clasificar o reducir la dimensionalidad. Zhou (2021) indica cómo los modelos de aprendizaje automático infieren una función de mapeo mediante la identificación de patrones en los datos de entrenamiento.

Desde una perspectiva estadística, el objetivo es inferir las relaciones entre un conjunto de variables predictoras o independientes $X = (X_1, X_2, \dots, X_p)^T$ y una variable respuesta o dependiente Y . Esta relación se expresa como $Y = f(X) + \epsilon$, donde $f(X)$ representa la función desconocida que describe la estructura de los datos y ϵ representa el error aleatorio o ruido, con media cero e independiente de X . Las técnicas de aprendizaje automático se dividen en tres grupos:

- Supervisado: en el entrenamiento del modelo están disponibles tanto los datos de entrada X , como los de salida y , es decir, el modelo conoce los resultados que debería obtener mientras se entrena.
- No supervisado: el modelo solo recibe datos de entrenamiento, sin recibir los resultados esperados, de modo que el modelo se limite a encontrar patrones en los datos, reducir dimensiones o agrupar aquellos casos que sean similares. Esto puede ocurrir por no disponer de los datos de salida, o porque se busque explorar la estructura subyacente de la población. James et al. (2023) exponen cómo, en contraste con los modelos de aprendizaje automático supervisados, este tipo supone un desafío mucho mayor, definiendo a los modelos no supervisados como subjetivos.
- Por refuerzo: este tipo de aprendizaje se aleja de los dos mencionados anteriormente. Un agente realiza un gran número de veces la misma acción de forma iterativa. El agente recibe recompensas o castigos en función de sus resultados, por lo que aprende qué acciones reciben más recompensas y las prioriza, entrenándose así el modelo.

Con el concepto de aprendizaje automático, se exponen a continuación los fundamentos del aprendizaje conjunto.

3.1 APRENDIZAJE CONJUNTO

El *ensemble learning* o aprendizaje conjunto se fundamenta en que, si se combinan múltiples modelos simples, conocidos como aprendices base, se acaba obteniendo un modelo final más preciso que el de cualquiera de los modelos individuales por separado.

Los métodos de aprendizaje conjunto se dividen en tres grupos según la forma de entrenar los modelos: métodos paralelos o *bagging*, donde los modelos son independientes; métodos secuenciales o *boosting*, donde los modelos aprenden de los errores de los anteriores; o métodos de apilamiento o *stacking*, donde se fusionan varios modelos elaborados con técnicas independientes en base a un metamodelo.

3.1.1 BAGGING

Bagging es el acrónimo de *bootstrap aggregating* y es una técnica de *ensemble learning* diseñada para reducir la varianza de los modelos y evitar el *overfitting*.

En lugar de entrenar un solo modelo con todos los datos disponibles, los modelos de *bagging* generan múltiples subconjuntos de datos de entrenamiento, obtenidos mediante un muestreo aleatorio con reemplazo del conjunto original. Sobre cada uno de estos subconjuntos se realiza un modelo independiente, lo que da lugar a modelos con una alta varianza entre sí. Una vez entrenados, sus predicciones se combinan. En problemas de clasificación, esto se obtiene mediante votación mayoritaria o el promedio de las probabilidades predichas. En problemas de regresión, se calcula el promedio aritmético de las predicciones de todos los modelos.

El principal modelo de *bagging* es *Random Forest*. En este algoritmo se entrenan árboles de decisión sin podar de forma paralela e independiente, introduciendo aleatoriedad mediante el remuestreo con reemplazo de los datos originales o *bootstrap*. Para prevenir el *overfitting*, limita la optimización del particionamiento de cada nodo a un subgrupo cuyo tamaño es la raíz cuadrada del número de variables predictoras. Gracias a esto, es especialmente bueno para tamaños de muestra reducidos. Cada árbol realiza una predicción y la predicción final del modelo se obtiene seleccionando la predicción más repetida en los árboles. Si se denota x_0 al caso que se quiere predecir, $\hat{C}_{RF}(x_0)$ a la predicción que da el modelo y $\hat{T}_i(x_0)$ a la predicción del árbol i , viene dada por la siguiente expresión.

$$\hat{C}_{RF}(x_0) = \text{moda}\{\hat{T}_1(x_0), \hat{T}_2(x_0), \dots, \hat{T}_B(x_0)\}$$

3.1.2 BOOSTING

Los métodos de *boosting* se basan en un aprendizaje secuencial, donde se empieza trabajando con unos estimadores débiles que iteración a iteración acaban convirtiéndose en los estimadores finales o fuertes. El principal objetivo de esta técnica es reducir el sesgo que tienen los modelos. Para que esto ocurra, en cada iteración se entrena al modelo en base a errores de predicción del modelo anterior.

Algunos modelos asignan más peso a aquellas observaciones donde el modelo anteriormente falló, de forma que se tengan más en cuenta en la siguiente iteración. Otros eligen no predecir la variable de respuesta Y , sino los residuos generados por los modelos en las iteraciones previas. Los modelos de *boosting* suelen usar árboles poco profundos como estimadores, al ser estos estimadores débiles, fácilmente controlables y presentar un alto sesgo que se puede ir corrigiendo. Esto también se cumple para las tres técnicas principales de este tipo: *AdaBoost*, *XGBoost* y *LightGBM*.

AdaBoost entrena secuencialmente árboles de profundidad unitaria o *stumps*, modificando paso a paso el peso de cada observación, aumentando los pesos de los casos mal clasificados y reduciendo el de los correctos. De esta forma, el modelo se centra en corregir los errores que había en la iteración anterior hasta llegar a la última.

XGBoost y *LightGBM* parten de la misma base, el *gradient boosting*. Ambos construyen modelos aditivos de árboles secuenciales con el objetivo de minimizar una función de pérdida diferenciable. En cada iteración se aproxima la optimización mediante una expansión de Taylor

de segundo orden. En *XGBoost* se introducen penalizaciones cuadráticas en la función objetivo del árbol para evitar *overfitting*, mientras que en el caso de *LightGBM* se utiliza un crecimiento de árbol enfocado en las hojas para reducir el coste computacional y optimizar el rendimiento.

3.1.3 STACKING

Los métodos de *stacking* combinan distintos modelos de aprendizaje automático de naturalezas diversas. Este proceso se realiza en dos niveles. El nivel 0 está formado por una colección de modelos heterogéneos, de forma que cada uno de estos modelos genera una predicción en base a los datos de entrada X que disponemos. El nivel 1 consiste en un metamodelo, generalmente más simple que los anteriores, que se entrena usando como variable de entrada las predicciones obtenidas en el nivel 0. Džeroski y Ženko (2004) exponen como esta estructura hace que los resultados del metamodelo de nivel 1 sean consistentemente mejores que el clasificador individual.

Para la correcta aplicación de un modelo de *stacking*, es crítico aplicar también validación cruzada, al ser estos tremendamente propensos a padecer de *data leakage*. Para corregir esto se suele emplear una variación de la validación cruzada llamada *out of fold*, donde se dividen los datos en K pliegues, entrenando cada modelo con $K-1$ de ellos y haciendo las predicciones sobre el pliegue restante.

3.2 MODELOS DE APRENDIZAJE AUTOMÁTICO NO SUPERVISADO

3.2.1 CLUSTERING

El *clustering* es una técnica de aprendizaje automático no supervisado cuyo objetivo es agrupar los datos en subgrupos llamados clústeres. Los individuos u observaciones que forman un clúster deben tener cohesión interna, es decir, son homogéneos entre sí; los individuos de distintos clústeres presentan separación externa, haciendo que, al comparar un clúster con otros, sean heterogéneos. Según el método de agrupamiento, existen tres tipos de *clustering*:

- Particional: divide el conjunto de datos en K grupos de forma que todas las observaciones formen parte de uno de los grupos, optimizando algún criterio de proximidad.
- Jerárquico: usa una estructura de árbol llamada dendrograma. Si el árbol se va formando de arriba abajo, separando el grupo en subgrupos, se denomina divisivo; y si va de abajo a arriba añadiendo casos, es aglomerativo.
- Basado en densidad: agrupa basándose en la concentración espacial de los puntos, lo que ayuda a aislar el ruido.

Existen multitud de formas de medir la similitud entre los casos, pero generalmente se emplea la distancia euclídea o la distancia de Manhattan. Dadas dos observaciones $p = (p_1, \dots, p_d)^T$ y $q = (q_1, \dots, q_d)^T$, la definición de estas distancias es:

- Distancia euclídea: se basa en el cálculo geométrico de la distancia, calculando la longitud del segmento que une los dos puntos.

$$d_{\text{eucl}}(p, q) = \sqrt{\sum_{j=1}^d (p_j - q_j)^2}$$

- Distancia de Manhattan: trabaja con las diferencias absolutas, lo que hace que no sea tan sensible a valores extremos u *outliers*.

$$d_{\text{Manh}}(p, q) = \sum_{j=1}^d |p_j - q_j|$$

3.2.2 CLUSTERING K-MEANS

Es un método iterativo donde el algoritmo busca agrupar las observaciones en una serie de clústeres disjuntos, minimizando la suma de las distancias cuadráticas al centroide de cada clúster, conocido como WCSS. A esta suma de distancias cuadráticas se la conoce como inercia y se usa para el cálculo del número de clústeres mediante el método del codo.

El método del codo se basa en graficar el valor de la inercia o varianza no explicada para distintos valores de K . En el gráfico se ve cómo, a partir de un valor de K , apenas disminuye la inercia. Existe otro método conocido como coeficiente de silueta que mide la cohesión interna, utilizando la distancia promedio entre los elementos de un clúster y del clúster vecino más cercano, dando un valor entre -1 y 1. A la hora de decidir el número de clústeres K , se busca un equilibrio entre ambas técnicas y se deben considerar también las características de los datos.

Una vez definido el número de clústeres, si denotamos el conjunto de grupos como $\mathcal{C} = \{C_1, C_2, \dots, C_K\}$, y al vector de medias del clúster C_k , o centroide como μ_k : el objetivo del modelo es el siguiente:

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K W(C_k) = \min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2$$

Para ello, el algoritmo alterna dos fases de forma cíclica hasta llegar a la convergencia. En la fase de asignación, se agrupa cada observación al clúster cuyo centroide esté más cerca. Tras ello, se recalculan los centroides y se repite la fase de asignación.




Ilustración 3: Ejemplo de iteraciones de clustering k-means. Fuente: Yerra (2018)

3.2.3 ANÁLISIS DE COMPONENTES PRINCIPALES (PCA)

El análisis de componentes principales es una técnica de aprendizaje automático no supervisado que busca reducir la dimensionalidad mediante proyección lineal. Su objetivo es transformar un conjunto de variables que pueden o no estar correlacionadas en un nuevo conjunto de variables incorrelacionadas, de forma que se mantenga la máxima cantidad de información posible. Para aplicar esta técnica, primero se deben estandarizar los datos. Así, la proporción de varianza explicada o PVE por la m -ésima componente principal se calcula a partir de las puntuaciones de las componentes z_{im} o, de manera equivalente, a partir de los autovalores asociados λ_m :

$$PVE_m = \frac{\sum_{i=1}^N z_{im}^2}{\sum_{j=1}^p \sum_{i=1}^N x_{ij}^2} = \frac{\lambda_m}{\sum_{j=1}^p \lambda_j}$$

3.3 REGRESIONES

Una regresión es una técnica de aprendizaje automático supervisado que se utiliza para modelar, cuantificar o analizar la relación entre una variable de respuesta Y , y una o más variables explicativas X . Los modelos de regresión estudian cómo se comporta el valor de Y a medida que varían los valores de X . Existen una gran cantidad de tipos de regresiones, por lo que solo se desarrollan aquellos modelos que se han empleado en la parte práctica.

3.3.1 REGRESIÓN LINEAL

Es el modelo más básico y clásico. Se asume la existencia de una relación lineal entre una única variable predictora x y la variable respuesta continua y , de forma que el modelo tiene la siguiente estructura:

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$

Donde β_0 es el intercepto o constante de la recta de regresión, β_1 es la pendiente del modelo y ϵ_i es el error aleatorio.

Para estimar los coeficientes, se minimiza la suma de los residuos cuadráticos. La pendiente β_1 representa el cambio esperado de y por cada unidad que aumenta x , *obtenida* como:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Mediante la pendiente se calcula el intercepto, obteniendo el valor donde la recta corta el eje de ordenadas y .

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

En el caso de la regresión lineal múltiple, se tienen varias variables explicativas, lo que da lugar a la siguiente estructura:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_p x_{pi} + \epsilon_i$$

Denotando al número de variables explicativas p , existen p vectores de x , de forma que cada uno da información sobre una de las variables que se combinan en una matriz $\mathbf{X}$ de tamaño $(n \times (p + 1))$, que contiene además una columna de unos para β_0 . A su vez, también existe un β_j para cada variable, que junto con β_0 dan lugar a un vector de parámetros β , de tamaño $p + 1$. Dichos parámetros tratan de predecir un vector de respuestas $\mathbf{Y}$ de tamaño n , dando lugar a un error ϵ . Esto da lugar a la expresión matricial:

$$\mathbf{Y} = \mathbf{X}\beta + \epsilon$$

Finalmente, si se asumen los supuestos de Gauss-Markov, es decir, que los errores tengan media cero, sean homocedásticos, estén incorrelacionados y sean independientes de las variables explicativas, el estimador de mínimos cuadrados ordinarios o MCO es el mejor estimador lineal insesgado. Dicho estimador puede ser obtenido de la siguiente expresión siempre y cuando la matriz $\mathbf{X}^T \mathbf{X}$ sea invertible, es decir:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

3.3.2 REGRESIÓN SEGMENTADA

En el caso de la regresión segmentada o regresión lineal por tramos, se realiza una o varias particiones de la variable independiente, de forma que cada uno de estos tramos tiene su propia recta de regresión. Se usa en casos donde ha habido cambios espontáneos y bruscos.

Se llama al momento en el que ocurre este cambio brusco, punto de quiebre o *breakpoint*, y se representa como t_0 . Para poder escribir la ecuación, se debe primero crear una variable *dummy* d_i , que es 1 si $x_i > t_0$ y 0 en caso contrario ($x_i \leq t_0$). Viene dada por la siguiente expresión:

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 (x_i - t_0) d_i + \epsilon_i$$

En esta expresión β_2 mide la diferencia que hay entre la pendiente del primer tramo y la del segundo tramo, es decir, la pendiente del segundo tramo es en realidad $\beta_1 + \beta_2$.

En algunos casos, el punto de quiebre t_0 se conoce de antemano debido a algún suceso importante, y se podrán estimar los coeficientes directamente mediante el método de mínimos cuadrados ordinarios. En caso de que se quiera estimar t_0 , el modelo se convierte en no lineal y se estiman los coeficientes mediante métodos iterativos, seleccionando el t_0 que minimice la suma de los residuos al cuadrado.

Para poder justificar el uso de la regresión segmentada se utiliza la prueba de Davies, un contraste de hipótesis que evalúa la significancia de un punto de quiebre en una relación lineal, bajo la premisa de que su localización es desconocida. De esta forma, se establece la hipótesis nula H_0 : no existe punto de quiebre en la relación; y H_1 : existe al menos un punto de quiebre. Como en este método, el parámetro t_0 no está identificado, viola los supuestos estándar del test de razón de verosimilitud, haciendo que no sea posible usar la distribución Chi-cuadrado.

Para evitar esta limitación, se emplea un método que modela el estadístico de contraste M , como un proceso estocástico parametrizado por el valor del punto de quiebre en un intervalo factible $[t_{min}, t_{max}]$, calculando la cota superior del p-valor acumulado del máximo del proceso sobre el rango:

$$p\text{-valor} \approx \Phi(-M) + V \exp\left(-\frac{M^2}{2}\right) (2\pi)^{-1/2}$$

Donde Φ es la función de distribución acumulada de la normal estándar, y V es la variación total del estadístico sobre el espacio del parámetro de quiebre.

3.3.3 REGRESIÓN LOGÍSTICA BINARIA

La regresión logística binaria es un método de aprendizaje supervisado aplicado a variables de respuestas binarias, por lo que la salida solo puede tomar dos valores, 0 o 1. El objetivo principal del modelo es estimar la probabilidad condicional de éxito, denotada como $p(x) = P(Y = 1 | x)$, en función de una única variable explicativa x .

A diferencia de la regresión lineal, no se modela la probabilidad de éxito de forma directa mediante una función lineal, puesto que para valores extremos se podrían obtener probabilidades menores que 0 o mayores que 1 y que se rompiera uno de los axiomas básicos de la probabilidad. Para solucionar este problema se utiliza la función sigmoide o logística, la cual restringe los datos haciendo que cualquier valor esté en el intervalo (0,1):

$$p(x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}} = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$

Sobre esta fórmula se realiza una transformación algebraica para expresarla en términos lineales. Al dividir $p(x)$ por su complementario $1 - p(x)$, se obtiene la razón de probabilidades u *odds*:

$$\frac{p(x)}{1 - p(x)} = e^{\beta_0 + \beta_1 x}$$

Si ahora se aplica el logaritmo natural a ambos lados de la igualdad, se eliminan las potencias dejando la fórmula del *logit* o *log odds*:

$$\ln\left(\frac{p(x)}{1 - p(x)}\right) = \beta_0 + \beta_1 x$$

Gracias a esto se obtiene un modelo donde, aunque la relación entre la probabilidad $p(x)$ y el predictor x no sea lineal, el logaritmo de la razón de probabilidades sí mantiene una relación lineal directa con la variable explicativa x .

Los parámetros se estiman mediante el método de máxima verosimilitud, maximizando la probabilidad de obtener los valores reales en la muestra de entrenamiento, siendo $p(x_i)$ la probabilidad estimada para la observación i en función de x_i , se obtiene:

$$(\beta_0, \beta_1) = \sum_{i=1}^n [y_i \ln(p(x_i)) + (1 - y_i) \ln(1 - p(x_i))]$$

3.3.4 REGRESIÓN LOGÍSTICA MULTINOMIAL.

Si la variable de respuesta presenta más de dos categorías, se adapta al modelo logístico binario a través de la formulación multinomial. El modelo fija una categoría de referencia que en este caso se va a denotar con la C y estima los *log-odds* de pertenecer a cada una de las clases $c \in \{1, \dots, C - 1\}$ frente al pivote seleccionado:

$$\ln \left(\frac{P(Y_i = c | x_i)}{P(Y_i = C | x_i)} \right) = \beta_{c0} + \beta_{c1}x_{1i} + \dots + \beta_{cp}x_{pi} = x_i^T \beta_c$$

Se entrenan $C-1$ vectores de coeficientes independientes β_c . En este caso se usa la función *softmax* para obtener las probabilidades, haciendo que el sumatorio de las probabilidades de cada clase dé uno:

$$P(Y_i = k | x_i) = \frac{e^{x_i^T \beta_k}}{1 + \sum_{j=1}^{C-1} e^{x_i^T \beta_j}}$$

Para la categoría de referencia C , la probabilidad de pertenecer a esta es:

$$P(Y_i = C | x_i) = \frac{1}{1 + \sum_{j=1}^{C-1} e^{x_i^T \beta_j}}$$

Para calcular los coeficientes, se optimiza la función de verosimilitud mediante aproximaciones numéricas. En la práctica, esto se resuelve aplicando el algoritmo de *Newton-Raphson* o el método de los mínimos cuadrados ponderados iterativos IRLS.

3.4 OTROS MODELOS DE APRENDIZAJE AUTOMÁTICO SUPERVISADO

3.4.1 K VECINOS MÁS CERCANOS (KNN)

KNN destaca por ser una técnica no paramétrica y no construir de forma explícita ningún modelo en la fase de entrenamiento. Cada vez que se evalúa un caso x_0 , calcula la distancia geométrica al resto e identifica los K más cercanos. Es necesario hacer un escalado de los datos previo a este análisis, puesto que, si en los datos hay distintas escalas, esto afecta a la distancia entre casos. También se debe seleccionar un número apropiado de K , buscando un equilibrio sesgo-varianza. Valores pequeños de K dan lugar a una gran cantidad de vecindarios pequeños, lo que hace que se obtengan modelos flexibles pero sensibles al ruido. Valores grandes dan lugar a vecindarios con muchos casos que incrementan el sesgo del modelo.

La probabilidad de que un caso x_0 se clasifique en una clase determinada viene dada por la proporción de sus K vecinos más cercanos que pertenecen a dicha clase. Llamando al conjunto

formado por los K vecinos más cercanos a la observación x_0 , $\mathcal{N}_0$ y a la función indicadora $I(\cdot)$, se calcula la probabilidad de que pertenezcan a cada clase j mediante:

$$Pr(Y = j | X = x_0) = \frac{1}{K} \sum_{i \in \mathcal{N}_0} I(y_i = j)$$

Finalmente, el modelo compara las probabilidades de cada clase y clasifica al caso x_0 en el valor que haya obtenido una mayor probabilidad, es decir, la categoría que tenga más vecinos entre los K más cercanos.

3.4.2 MÁQUINAS DE VECTORES DE SOPORTE

Las máquinas de vectores de soporte o SVM tratan de maximizar la distancia entre las clases encontrando un hiperplano de separación en un espacio multidimensional. Se basan en el estimador de margen máximo, y su procedimiento viene dado por el siguiente proceso de optimización:

$$\begin{aligned} & \max_{\beta_0, \beta_1, \dots, \beta_p, M} M \\ & \text{sujeto a } \sum_{j=1}^p \beta_j^2 = 1 \\ & y_i(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) \geq M \quad \forall i = 1, \dots, n \end{aligned}$$

Se debe hacer una corrección en la que se aplica el clasificador de margen blando o *soft margin classifier*, que emplea variables de holgura $\xi_i \geq 0$. En caso de no aplicarlo, un único dato mezclado de la otra clase en la frontera haría que no se pudiera encontrar la solución.

Al añadir estas variables de holgura al modelo, se permite que ciertas observaciones puedan violar el margen o estar colocadas en el lado incorrecto del hiperplano. Dando lugar a la variación del proceso anterior:

$$\begin{aligned} & \max_{\beta_0, \beta_1, \dots, \beta_p, \xi_1, \dots, \xi_n, M} M \\ & \text{sujeto a } \sum_{j=1}^p \beta_j^2 = 1 \\ & y_i(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) \geq M(1 - \xi_i) \quad \forall i = 1, \dots, n \\ & \xi_i \geq 0, \quad \sum_{i=1}^n \xi_i \leq C \end{aligned}$$

Donde C marca el límite de tolerancia que pueden violar el margen. Para llegar a la función de densidad final permitiendo incluir fronteras de decisión complejas y no lineales, se recurre a la formulación dual del problema, que permite aplicar el *Kernel trick*. En este método se proyectan las observaciones en un espacio de dimensión superior mediante la transformación $\Phi(x)$. En este espacio interno el producto interno de las observaciones se calcula como:

$$K(x_i, x_j) = \Phi(x_i)^T \Phi(x_j)$$

Gracias a esto, se obtiene la función de decisión final que clasifica a una observación x , a través del conjunto de vectores de soporte $\mathcal{S}$ es:

$$f(x) = \beta_0 + \sum_{i \in \mathcal{S}} \alpha_i K(x, x_i)$$

3.4.3 ÁRBOLES DE DECISIÓN

Este método consiste en dividir el espacio de variables predictoras en J regiones ortogonales y no solapadas, expresadas como $R_1, \dots, R_J$. En su versión de clasificación, el algoritmo asigna la clase que más se repite en las observaciones de entrenamiento que pertenezcan a esa región. La construcción del árbol se divide en dos fases secuenciales.

Se realiza primero una división binaria recursiva que comienza en la raíz del árbol, en la que busca de forma iterativa el predictor y el valor de coste que mejor segmenten los datos, actuando de forma voraz. Para evaluar las subdivisiones se utilizan medidas como el índice de Gini o la entropía, que toman valores de 0 cuando todos los casos de esta subdivisión pertenezcan a la misma clase.

Posteriormente, se realiza una corrección con el objetivo de evitar el *overfitting*, a la que se denomina poda del árbol. En lugar de parar el crecimiento del árbol, se deja que crezca sin limitarlo, para recortar después las ramas mediante un método conocido como poda por complejidad de costes. Este método penaliza el tamaño excesivo, buscando un equilibrio entre el tamaño del árbol y su error de predicción.

3.4.4 NAIVE BAYES

Como su nombre indica, se basa en la aplicación del teorema de Bayes. Usando este teorema, se obtiene un algoritmo clasificador de tipo generativo bajo el supuesto de que todos los predictores son condicionalmente independientes entre sí dada la clase de la respuesta c . La probabilidad a priori $P(Y = c)$ se calcula a partir de las frecuencias observadas, y la probabilidad a posteriori se expresa:

$$P(Y = c | \mathbf{x}) \propto P(Y = c) \prod_{j=1}^p P(x_j | Y = c)$$

En caso de que las variables predictoras sean continuas, la verosimilitud condicional $P(x_j | Y = c)$ se modela asumiendo que sigue una distribución normal:

$$f(x_j | Y = c) = \frac{1}{\sqrt{2\pi\sigma_{cj}^2}} \exp\left(-\frac{(x_j - \mu_{cj})^2}{2\sigma_{cj}^2}\right)$$

4. VALIDACIÓN Y EVALUACIÓN

Cuantificar la calidad de las predicciones que han realizado los modelos de aprendizaje automático y que se ajusten a la realidad forma parte de la metodología aplicada para obtener modelos estadísticamente válidos. Este proceso se estructura en dos fases complementarias denominadas validación y evaluación.

La fase de validación busca seleccionar el modelo óptimo y calibrar sus hiperparámetros mediante la comparación de diferentes configuraciones. Por otro lado, la fase de evaluación busca estimar la capacidad predictiva definitiva y el error de generalización del modelo elegido. En caso de trabajar con predicciones de variables numéricas, se usan medidas basadas en error o varianza explicada como el error cuadrático medio o el R^2 ; si la variable objetivo es categórica, se crean medidas basadas en la proporción de aciertos, como la exactitud o el F1 score; y si, por el contrario, es ordinal, se suele recurrir a coeficientes de correlación por rangos o métricas de concordancia específicas.

En el proceso de entrenar los modelos, existen unas variables externas que el usuario define para controlar cómo se comporta el modelo, los hiperparámetros, que son ajustados y optimizados mediante las técnicas de validación.

4.1 VALIDACIÓN

En caso de que a la hora de evaluar se usaran los mismos datos que se emplearon anteriormente para entrenar el modelo, se daría lugar a predicciones sesgadas, con errores estimados muy inferiores a los reales. Hastie *et al.* (2009) exponen cómo esto es especialmente grave en modelos con alta flexibilidad, que, debido a la libertad que tienen, acaban memorizando las fluctuaciones aleatorias en lugar de entender la estructura de los datos, haciendo que se obtenga un modelo que a priori parece idóneo, pero que a la hora de la verdad da lugar a predicciones inexactas. A este fenómeno se lo conoce como *overfitting*.

La única forma correcta de obtener una estimación precisa, fiable e insesgada del modelo es mediante el uso de observaciones independientes en la fase de evaluación y en la fase de entrenamiento. Existen diversas formas de realizar esto, que se exponen a continuación.

4.1.1 TRAIN/TEST SPLIT

Es el enfoque más sencillo e intuitivo. Al no poder entrenar y evaluar el modelo con los mismos datos, se divide el conjunto de observaciones D en dos grupos: un conjunto compuesto de alrededor del 80 % de datos, que se empleará en entrenar al modelo y se denomina D_{train} y el conjunto de prueba D_{test} que lo evaluará posteriormente. Estos dos conjuntos deben ser disjuntos; es decir:

$$D = D_{\text{train}} \cup D_{\text{test}}, \quad D_{\text{train}} \cap D_{\text{test}} = \emptyset$$

De esta forma, el modelo nunca se evalúa con las mismas observaciones con las que se entrenó, por lo que se esperaría que diera lugar a modelos correctos. En la práctica, esta técnica sufre de graves problemas, siendo el más importante la aleatoriedad que introduce al

dividir los datos. En caso de obtener un conjunto de entrenamiento sesgado, el modelo se optimiza para adaptarse a esos sesgos. En caso de que sea el conjunto de prueba el sesgado, las métricas dejan de representar la capacidad predictiva o clasificadora del modelo. Si se asume el reparto estándar 80/20, el conjunto de entrenamiento no dispone de un 20% de los datos, siendo especialmente grave en bases de datos pequeñas.




Ilustración 4: Representación visual del train/test split. Fuente: Lau et al. (2023)

4.1.2 VALIDACIÓN CRUZADA

Esta técnica consiste en dividir la base de datos múltiples veces en subgrupos de *train* y *test*, evaluando el modelo con cada subdivisión. Con esto se busca reducir el factor de aleatoriedad que existe en el *train/test* y se consigue proporcionar estimaciones del rendimiento del modelo más estables y confiables. En casos donde la base de datos es muy pequeña, es útil utilizar validación cruzada para no perder esos escasos y valiosos datos con los que entrenar el modelo.




Ilustración 5: Representación gráfica de la validación cruzada. / Fuente: Irizarry (2019)

Existen diversos métodos de validación cruzada, como el *K-folds* o el *out of fold*, pero el más completo es la validación cruzada anidada o *nested cross validation*.

4.1.3 VALIDACIÓN CRUZADA ANIDADA

La validación cruzada anidada o *nested cross validation* mantiene las bases de la validación cruzada, añadiendo también a este proceso la optimización de hiperparámetros. Para poder hacer ambas, se separa en dos *loops* o bucles junto con una fase final de evaluación.

El objetivo del bucle externo es estimar el error de generalización. Para ello, divide los datos en K pliegues externos, de forma que para cada iteración se selecciona un conjunto de datos

$D_{\text{test},k}$ que queda reservado para la prueba externa y el resto de los datos $D_{\text{train},k} = D \setminus D_{\text{test},k}$, se usa para optimizar el modelo.

En el bucle interno, para cada conjunto de entrenamiento externo $D_{\text{train},k}$, se realiza una validación cruzada de L pliegues con el objetivo exclusivo de seleccionar los hiperparámetros óptimos. El conjunto $D_{\text{train},k}$ se divide en L pliegues internos. Se entrena el modelo sobre $L-1$ pliegues internos para cada combinación de hiperparámetros θ y se evalúa sobre el pliegue restante, seguido del cálculo del error de validación expresado como:

$$CV_{\text{inner}}(\theta) = \frac{1}{L} \sum_{l=1}^L E_l(\theta)$$

Finalmente, se selecciona la configuración de hiperparámetros θ_k^* que minimicen la función de pérdida:

$$\theta_k^* = \arg \min_{\theta \in \Theta} CV_{\text{inner}}(\theta)$$

A continuación, se indica una representación visual del funcionamiento de los bucles internos y externos.




Ilustración 6: Diagrama de funcionamiento de validación cruzada anidada/ Fuente: Infanti et al. (2023)

En la evaluación se reajusta el modelo empleando la combinación óptima obtenida en el *loop interno*, usando todo el conjunto de entrenamiento externo, $D_{\text{train},k}$ obteniendo una estimación $\hat{f}_k$. Esta estimación se utiliza para obtener la estimación del error de generalización por estimación de la iteración k :

$$E_k = \frac{1}{|D_{\text{test},k}|} \sum_{i \in D_{\text{test},k}} L(y_i, \hat{f}_k(x_i))$$

El estimador global se obtiene del promedio de estos errores externos:

$$Nested_CV = \frac{1}{K} \sum_{k=1}^K E_k$$

El principal inconveniente de la validación cruzada anidada es que incrementa considerablemente el tiempo de computación. Sin embargo, las ventajas de esta técnica compensan claramente dicha limitación. Adicionalmente, no existen alternativas mejores, por lo que esta técnica se aplica en una gran cantidad de estudios científicos en campos muy diversos.

4.2 MÉTRICAS DE EVALUACIÓN

4.2.1 DEFINICIÓN Y FORMALIZACIÓN DE LAS MÉTRICAS DE EVALUACIÓN.

En variables categóricas binarias se considera un 1 como positivo y un 0 como negativo. Si en vez de binarias son multinomiales, se debe aplicar una estrategia llamada one vs rest o OVR, que consiste en evaluar cada categoría de forma independiente, haciendo que, si el modelo predice la categoría que se está estudiando, se considere un positivo y, si predice cualquier otra, sea negativo.

Con estos valores se puede aplicar una matriz de confusión. En ella se representan las predicciones en cuatro grupos: verdaderos positivos o VP, si se predice positivo y el caso real es positivo; verdaderos negativos o VN, si se predice negativo y el caso real es negativo; falsos positivos o FP, si se predice positivo y el caso real no lo es; o falsos negativos o FN, si se predice negativo y el caso real es positivo.

Estos cuatro conceptos son vitales para la evaluación de modelos de clasificación, puesto que la gran mayoría de las fórmulas se obtienen combinándolos de alguna forma. Este es el caso de la precisión y de la sensibilidad. La precisión mide la capacidad predictiva del modelo para los casos seleccionados como positivos, dando una razón de los aciertos en caso de predecir positivo.

$$\text{Precisión} = \frac{VP}{VP + FP}$$

La sensibilidad mide la capacidad del modelo para clasificar de forma correcta los casos reales positivos, representando la razón de los aciertos sobre todos los casos positivos.

$$\text{Sensibilidad} = \frac{VP}{VP + FN}$$

Mediante la media armónica de ambos componentes se consigue obtener el F1-Score, penalizando los desequilibrios extremos entre precisión y sensibilidad. Esto hace que, para obtener valores aceptables del F1 Score, los modelos deban obtener puntuaciones elevadas tanto en la precisión como en la sensibilidad.

$$F1 = \frac{2 \cdot VP}{2 \cdot VP + FP + FN}$$

El F1-Score Macro evalúa el rendimiento global tratando a todas las categorías con el mismo peso, sin importar el tamaño de cada grupo.

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k$$

Por otra parte, cuando el modelo proporciona salidas en términos de probabilidad, se puede evaluar el error absoluto medio (MAE) en el ámbito de la clasificación. Este estadístico cuantifica la diferencia absoluta promedio entre la probabilidad estimada por el clasificador para la clase positiva y la etiqueta real observada (0 o 1):

$$\text{MAE}_{\text{prob}} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{p}_i|$$

En problemas de clasificación, donde las clases representan categorías ordenadas, el MAE evalúa la distancia absoluta media entre el índice de la clase real y_i y el índice de la clase predicha $\hat{y}_i$.

$$\text{MAE}_{\text{ord}} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

La curva Receiver Operating Characteristic, más conocida como curva ROC, es una de las principales herramientas para evaluar los modelos de clasificación. Antes de desarrollarla, se debe definir a la ratio de falsos positivos (RFP):

$$\text{RFP} = \frac{\text{FP}}{\text{FP} + \text{VN}}$$

El área bajo la curva ROC o AUC-ROC equivale a la integral de la sensibilidad respecto al ratio de falsos positivos en el intervalo $(0, 1)$.

$$\text{AUC} = \int_0^1 \text{Sensibilidad}(\text{RFP}) d(\text{RFP})$$

Para la clasificación multinomial con K clases, la métrica AUC se generaliza mediante dos enfoques de agregación desarrollados para evaluar el comportamiento global del clasificador:

El primer enfoque se conoce como AUC-ROC-OVR y usa el mismo concepto de *One vs. Rest* que se explicó anteriormente. Para obtenerlo, se calcula el promedio, comparando de manera independiente cada clase k , frente a la unión de las restantes $K - 1$ clases. El estimador del AUC-ROC-OVR pondera el resultado de cada una de las K clasificaciones binarias según la prevalencia de cada clase en la muestra:

$$\text{AUC}_{\text{OVR}} = \sum_{k=1}^K P(C_k) \cdot \text{AUC}(C_k, \text{resto})$$

Donde $P(C_k)$ representa la proporción de observaciones pertenecientes a la clase C_k en el conjunto de datos y $\text{AUC}(C_k, \text{resto})$ es el área bajo la curva obtenida al tratar a la clase C_k como la clase positiva y al resto como la clase negativa.

La otra variante se conoce como *One-vs-One* u OVO, y calcula el AUC pareado para todas las combinaciones posibles de clases sin considerar a las demás. El AUC total se define como el promedio simple de los valores de AUC pareados obtenidos para cada par de clases (j, k) :

$$\text{AUC}_{\text{OVO}} = \frac{2}{K(K-1)} \sum_{1 \leq j < k \leq K} \hat{A}(j, k)$$

Se denomina $\hat{A}(j, k)$ al promedio del AUC obtenido al contrastar la clase j frente a la clase k y viceversa:

$$\hat{A}(j, k) = \frac{A(j | k) + A(k | j)}{2}$$

Donde $A(j | k)$ es la probabilidad de que una observación elegida al azar perteneciente a la clase j tenga una mayor probabilidad estimada de pertenecer a la clase j que la de una observación que haya sido elegida aleatoriamente.

4.2.2 INTERPRETACIÓN DE LAS METRICAS DE EVALUACIÓN

En función del ámbito en el que se encuentre un estudio, la forma en la que se interpretan estas métricas cambia radicalmente. Provost y Fawcett (2013) exponen cómo en ámbitos médicos, los test tienen que ser mucho más rigurosos, por lo que se buscan valores casi perfectos, ya que la importancia de un fallo ya sea falso negativo o falso positivo, al detectar una enfermedad puede suponer consecuencias graves. En otros ámbitos como el marketing, ocurre lo contrario, si se consigue que una tasa de conversión del 1% se aceptan a los modelos como viables. También indican que para que un modelo sea bueno, debe incrementar el valor neto respecto a no hacer nada, superar a un modelo base y optimizar el umbral de decisión.

5. ANÁLISIS EXPLORATORIO DE LOS DATOS

Tukey (1977), su creador, define al análisis exploratorio de datos o EDA como una etapa previa e indispensable en la modelización estadística, que permite descubrir la estructura interna de los datos, identificar anomalías y formular hipótesis.

Su función es examinar el conjunto de datos antes de aplicar cualquier modelo de predicción o clasificación, lo que permite comprender la estructura subyacente de las variables, identificar y tratar anomalías, y refinar la selección de características. Si bien existen muchas formas de estructurarlo, en este apartado se usan los cuatro siguientes: comprensión inicial, tratamiento de datos atípicos y faltantes, análisis bivariado de las variables y selección de las variables predictoras del modelo final.

5.1 COMPRENSIÓN INICIAL

Esta fase inicial del EDA consiste en realizar una exploración sencilla de los datos, examinando individualmente cada una de las variables con el objetivo de tener una noción básica de los datos. Para las variables cuantitativas, se analizan estadísticos descriptivos como la media, la desviación típica, la asimetría y la curtosis, apoyándose en representaciones gráficas univariantes para localizar visualmente la concentración y simetría de las observaciones; mientras que, para variables categóricas, se realiza un recuento y se estudia la distribución de frecuencias de sus clases, buscando detectar posibles desequilibrios en las categorías, lo que podría suponer problemas posteriormente o dar lugar a combinar dos categorías.

5.2 TRATAMIENTO Y DETECCIÓN DE DATOS FALTANTES Y VALORES ATÍPICOS

Una vez se tienen unas nociones generales de cómo son los datos, se debe estudiar si existen datos faltantes. En caso de que se encuentren, se deberá realizar un conteo, estudiar su distribución y analizar si han sido causados por azar o si existe alguna razón que haya hecho que se hayan eliminado sistemáticamente. Siguiendo la estructura definida por Little y Rubin (2019), se habla de pérdida completamente al azar o MCAR, cuando no se pueda observar ninguna razón aparente que explique por qué un dato es faltante, ya sea estudiando el individuo o la categoría. En caso de que haya alguna razón que haya provocado que un dato sea faltante, sin pertenecer a la propia variable en la que se encuentra, es decir, sea causada por los valores de otras variables, se le considera como pérdida al azar o MAR. El último y más problemático caso, conocido como pérdida no al azar o MNAR, ocurre cuando la causa de que no haya un valor está en el propio valor no observado, es decir, el valor de la variable es la causa de la ausencia.

Una vez descritos, se debe tomar una decisión sobre la forma en la que se van a tratar los datos faltantes. Se pueden eliminar directamente los individuos o variables con casos vacíos, pero esto da lugar a una pérdida considerable de información, por lo que solo se recomienda para datos faltantes de tipo MCAR o cuando la proporción de datos faltantes es muy baja.

Otra opción es imputar los datos, es decir, sustituir el valor nulo por otro que se puede calcular mediante estadísticos simples, como la moda o la mediana, o incluso por modelos predictivos complejos, entre los que destaca la imputación múltiple por ecuaciones encadenadas o MICE,

ya que añade aleatoriedad para poder generar datos más realistas. Este método se aplica cuando existen datos perdidos de tipo MAR, si la proporción de datos perdidos es considerable o si se dispone de una pequeña base de datos que no se puede reducir más.

El caso final se aplica cuando se tienen sospechas de que los datos faltantes son de tipo MNAR. En este caso, al existir una razón en la propia variable que explique la ausencia del dato, se suele decidir crear una categoría formada por todos los valores faltantes, ya que aporta información y puede ser útil posteriormente.

Los *outliers* o valores atípicos son observaciones que se desvían de manera extrema del patrón general de la distribución. Para su detección se emplea de forma estándar el criterio de Tukey basado en el rango intercuartílico (IQR). Si definimos los cuartiles primero y tercero como Q_1 y Q_3 respectivamente, el rango intercuartílico se calcula como:

$$IQR = Q_3 - Q_1$$

A partir del rango intercuartílico, se definen los límites inferior y superior del intervalo de Tukey:

$$[Q_1 - 1.5 \cdot IQR, \quad Q_3 + 1.5 \cdot IQR]$$

Cualquier observación fuera de este intervalo se considera como un valor atípico moderado. Si se amplía la constante a $3 \cdot IQR$, los límites resultantes identifican valores atípicos extremos.

En contextos donde existen dependencias entre variables predictoras, la detección univariante es imprecisa, requiriendo un enfoque multivariante. Para ello se calcula la distancia de Mahalanobis (D_M), ya que escala las variables según su varianza y corrige el efecto de la correlación, haciendo que desaparezca el problema anterior. Para ello, cuantifica la distancia de una observación multivariante x respecto al vector de medias poblacionales μ , teniendo en cuenta la matriz de covarianzas Σ :

$$D_M(x) = \sqrt{(x - \mu)^T \Sigma^{-1} (x - \mu)}$$

5.3 ANÁLISIS BIVARIADO DE LAS VARIABLES

Con la muestra depurada, se comienza el análisis bivariado, que se presenta como el paso fundamental para comprender el comportamiento conjunto de las variables. El enfoque de este proceso es la exploración de cómo interactúan las variables predictoras, tanto entre sí como con la variable de respuesta. Para ello, se combina la inspección gráfica a través de diagramas de caja y matrices de correlación con contrastes de hipótesis no paramétricos, lo que permite demostrar estadísticamente si las diferencias observadas entre las distintas categorías de la respuesta presentan patrones significativos.

Para evaluar la asociación lineal entre variables cuantitativas continuas, se calcula la matriz de correlaciones de Pearson, donde se calcula el coeficiente de correlación de Pearson para cada par de variables. El coeficiente de correlación lineal de Pearson ($\rho_{X,Y}$) se define como el cociente entre la covarianza de las variables y el producto de sus desviaciones típicas:

$$\rho_{X,Y} = \frac{Cov(X,Y)}{\sigma_X \sigma_Y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

Cuando las variables no presentan una relación lineal, sino una tendencia monótona, se aplica en su lugar el coeficiente de correlación por rangos de Spearman (r_s), que consiste en representar la diferencia entre los rangos de cada observación:

$$r_s = 1 - \frac{6\sum d_i^2}{n(n^2 - 1)}$$

Una vez obtenidos todos los coeficientes, se integran en una matriz simétrica que suele ir combinada con mapas de calor, cuyo color representa si la correlación es positiva o negativa, y la intensidad de estos colores indica el valor absoluto del coeficiente.




Ilustración 7: Ejemplo de matriz de correlaciones con heat map. / Fuente: Kassambara, A. (2024)

Cuando la variable de respuesta es categórica y las variables predictoras son cuantitativas, la relación bivariada se analiza visualmente mediante *box plots* condicionados por clase. Estos gráficos muestran la distribución de la variable numérica para cada categoría de la respuesta, representando la mediana, los cuartiles y los *outliers* potenciales identificados mediante el criterio de Tukey.

Para evaluar si la distribución de una variable cuantitativa difiere de manera significativa según las categorías de la variable respuesta, se emplean contrastes de hipótesis. Se evalúa mediante Shapiro-Wilk la normalidad; si las variables siguen una distribución normal, se aplica ANOVA y en caso contrario, Kruskal-Wallis. Como el segundo es el caso que ocurre en el marco práctico, es también el que se explica. Kruskal-Wallis se aplica para estudiar de forma bivariada qué variables predictoras influyen por sí solas en la de respuesta. Para ello evalúa si las K muestras independientes provienen de poblaciones con distribuciones idénticas, ordenando la totalidad de las observaciones conjuntamente y se calcula el estadístico de prueba H :

$$H = \frac{12}{n(n+1)} \sum_{k=1}^K \frac{R_k^2}{n_k} - 3(n+1)$$

donde n es el tamaño muestral total, n_k es el tamaño de la muestra de la categoría k , y R_k es la suma de los rangos asignados a las observaciones de la clase k . Bajo la hipótesis nula de que todas las categorías comparten la misma distribución de probabilidad, el estadístico H se distribuye asintóticamente como una variable chi-cuadrado con $K - 1$ grados de libertad:

$$H \sim \chi_{K-1}^2$$

5.4 SELECCIÓN DE VARIABLES MEDIANTE ANÁLISIS MULTIVARIADO

La selección final de las variables predictoras tiene como objetivo construir modelos estables, evitando problemas de *overfitting* y eliminando el ruido. Consta de una fase inicial de diagnóstico de problemas de multicolinealidad, seguida de un análisis del poder discriminatorio y predictivo de las variables cuantitativas respecto a la variable respuesta.

La multicolinealidad es la existencia de una relación lineal entre dos o más variables independientes de un modelo. Este fenómeno provoca estimaciones inestables y varianzas elevadas, complicando la capacidad para saber el efecto individual de cada variable predictora sobre la variable de respuesta.

Para cuantificar el grado de colinealidad de cada variable predictora X_j , se calcula el Factor de Inflación de la Varianza (VIF). El método consiste en ajustar una regresión lineal auxiliar para cada una de las variables explicativas utilizando al resto como variables independientes:

$$X_{ij} = \beta_0 + \sum_{k \neq j} \beta_k X_{ik} + \varepsilon_{ij}$$

A partir del coeficiente de determinación R_j^2 obtenido en dicho ajuste auxiliar, el VIF de la variable X_j se define como:

$$\text{VIF}(X_j) = \frac{1}{1 - R_j^2}$$

El valor obtenido indica en qué proporción se incrementa la varianza del coeficiente estimado debido a la colinealidad. Un VIF igual a uno indica ausencia total de asociación lineal. Un valor del VIF superior a diez se interpreta como evidencia significativa de multicolinealidad, lo que justifica la eliminación de la variable.

Una vez que se han cribado aquellas variables que generan multicolinealidad, se pasa a estudiar de forma multivariada qué variables influyen en la variable de respuesta cuando se crea un modelo multivariante. Para ello, se realiza un análisis multivariante predictivo, como es el caso de la regresión logística multinomial explicada en el apartado 3.3.4; o se estudia si las variables tienen la capacidad para separar los datos según la categoría de la variable de respuesta, como es el caso del análisis discriminante lineal. Existe también la opción de realizar técnicas de aprendizaje automático no supervisado, pero como no han sido empleadas en el EDA del caso práctico, no se tratan en este apartado.

El Análisis Discriminante Lineal (LDA) se puede emplear como método supervisado de reducción de dimensiones para proyectar los datos y maximizar la separación entre categorías. El algoritmo busca una matriz de transformación $\mathbf{W}$ que maximice la razón de Fisher entre la variabilidad interclase ($\mathbf{S}_B$) y la variabilidad intraclase ($\mathbf{S}_W$):

$$J(\mathbf{W}) = \frac{\mathbf{W}^T \mathbf{S}_B \mathbf{W}}{\mathbf{W}^T \mathbf{S}_W \mathbf{W}}$$

Donde las matrices de dispersión se definen a partir de la media global y las medias de cada clase:

$$\mathbf{S}_B = \sum_{k=1}^K N_k (\mu_k - \mu)(\mu_k - \mu)^T$$

La solución del sistema determina las componentes discriminantes que permiten proyectar y visualizar los datos de autovectores de $S_W^{-1}S_B$ en dos o tres dimensiones, como se expresa a continuación:

$$S_W^{-1}S_B w = \lambda w$$

Tras obtener los resultados de la regresión multinomial múltiple y del análisis discriminante lineal, se toman las decisiones necesarias eliminando variables con p-valores altos en la regresión y bajos coeficientes discriminantes en LDA. En caso de considerarse necesario, se pueden utilizar también los resultados del ANOVA o Kruskal-Wallis que se aplicó en la fase biviada.

Con este último paso se finaliza el EDA, habiendo obtenido información sobre las variables tanto predictoras como de respuesta, depurado la base de datos mediante las transformaciones necesarias sobre los datos faltantes y valores atípicos, y realizado una serie de contrastes y análisis tanto bivariados como multivariados con los que se ha completado el EDA con la selección final de las variables.

6. CASO PRÁCTICO Y RESULTADOS

El marco práctico de este trabajo se va a dividir en dos apartados. El primero es un análisis de los perfiles de tiro entre los años 2010 y 2024, con el objetivo de estudiar cómo ha sido esta evolución, tanto a nivel global como por posiciones; el segundo consiste en la creación de un modelo de aprendizaje automático mediante validación cruzada anidada que permita predecir el resultado de un equipo en la fase de *playoffs* mediante sus estadísticas en la temporada regular.

Las bases de datos empleadas han sido obtenidas de *rHoops* en el primer caso y de Internet en el segundo. Tanto la descarga de la primera base de datos como la maquetación de ambas han sido realizadas en *RStudio*. El análisis estadístico posterior ha sido realizado en *Python* mediante *Google Colab*, empleando como librerías *Pandas* para trabajar con *dataframes*, *NumPy* y *SciPy* para realizar cálculos, *Matplotlib* y *Seaborn* para la realización de gráficos y *scikit-learn* y similares para los métodos de aprendizaje automático y otros contrastes estadísticos.

6.1 ESTUDIO DE LA EVOLUCIÓN DE LOS PERFILES DE TIRO

A partir de la base de datos de *rHoops*, donde se almacenaban datos sobre todas las jugadas de los últimos años, se ha hecho una selección de los datos de las 14 temporadas entre 2010 y 2024. Después, se ha realizado una criba, conservando solo los casos de tiro, se han creado cinco variables en función de la distancia de cada tiro, se han añadido datos físicos a cada jugador y se han agrupado los datos por temporada y jugador, eliminando los casos donde hubiera valores faltantes.

A continuación, se ha calculado la distancia a canasta y usándola, se clasificaron los tiros en cinco tipos: aro, cerca, media distancia, triple y tiro libre. De esta forma se obtiene una base de datos con 5669 casos y 23 variables, en la que cada caso es una temporada realizada por un jugador:

- jugador: nombre completo del jugador de la NBA.
- season: año en el que acaba la temporada correspondiente.
- Posición: posición de juego en la cancha. En concreto, son *guard*, *forward* y *center*.
- total_intentos: número total de lanzamientos intentados por el jugador en la temporada, incluyendo tiros de campo y tiros libres.
- partidos_jugados: cantidad de partidos en los que el jugador participó durante la temporada.
- intentos_tipo_tiro: número de lanzamientos intentados de un tipo de tiro.
- acierto_tipo_tiro: porcentaje o tasa de acierto en los lanzamientos realizados según la zona del campo (aro, cerca, media distancia, triple o tiro libre).
- proporcion_tipo_tiro: número de tiros de un tipo realizados entre el número de tiros total (aro, cerca, media distancia, triple o tiro libre).

- porcentaje_acierto_global: número de tiros totales encestandos dividido entre el número de tiros totales tirados.
- Altura: altura del jugador medida en metros.
- Edad: edad que tenía el jugador en el momento en el que inicia la temporada.
- Peso: peso del jugador en libras.

Una vez se ha descrito la base de datos, se procede a explicar la metodología aplicada.

Se aplicó primero un análisis de las componentes principales sobre las variables de proporción de tiro, que permite analizar los datos y se usan más tarde como ejes en los gráficos de *clustering k-means*. Se comparan estos clústeres con las posiciones y se usan las medias de cada grupo para explicar qué tipos de perfiles existen. Se evalúan también las posiciones por separado, dividiendo en tres grupos, en función de si la posición principal es *guard*, alero o *center*. En ambos casos se estudia la evolución de los clústeres con el paso del tiempo.

También se aplica una regresión segmentada para estudiar cómo han evolucionado el tiro de tres y el de media distancia y para comprobar si existe algún punto de ruptura donde la evolución se aceleró.

Al realizar el análisis de componentes principales sobre nuestras variables de proporción de tiro, se obtiene que, agrupando en dos componentes principales, el modelo mantiene un 73,95 % de la varianza, dividido en un 51,14 % para PC1 y 22,81 % para PC2. Las cargas de los componentes vienen dadas en la siguiente tabla:

Tabla 1: Pesos de cada variable en cada componente. / Fuente: elaboración propia con Python y Word.

Variable	PC1	PC2
proporcion_aro	-0,532	-0,125
proporcion_cerca	-0,382	-0,092
proporcion_media_distancia	0,226	0,866
proporcion_triple	0,541	-0,466
proporcion_tiro_libre	-0,476	0,094

Se puede apreciar cómo PC1 tiene cargas más negativas cuanto más cerca está el tiro del aro y que aumenta a medida que aumenta la distancia, por lo que esta componente nos indica qué tan tirador es un jugador. En el caso de PC2, las únicas variables con cargas significativas son la proporción de media distancia, con valor enorme de 0,866 y la proporción de triple, con una carga negativa de -0,466, así que se podría decir que esta variable estudia cómo de clásico es un jugador.

A continuación, se han aplicado tanto el método del codo como el uso del *silhouette score* para evaluar el número óptimo de clústeres para el *K-means* global:




Ilustración 8: Evaluación número clústeres caso global. / Fuente: elaboración propia con Python.

Si bien se aprecian unos valores bajos del coeficiente de silueta, esto ocurre por el alto solapamiento que hay en los perfiles de juego, especialmente al solo utilizar las proporciones de tiro para diferenciar unos jugadores de otros. En cuanto a la selección del número de clústeres, existen dos valores que serían razonables: $k=3$ y $k=4$. Se ha decidido trabajar con $k=4$ debido a la gran variabilidad de los datos y se ha aplicado el *clustering K-Means*.




Ilustración 9: Clústeres obtenidos en el caso global. / Fuente: elaboración propia con Python.

Se puede apreciar que los datos han formado un triángulo, habiendo un clúster en cada una de las tres esquinas y otro en la parte central. Teniendo en cuenta que representaba cada componente principal, se esperaría que el clúster 0 tuviera un perfil de tiro equilibrado, el clúster 1 integrara a los tiradores de media distancia, el clúster 2 representase a los no tiradores y, finalmente, en el clúster 3 se encontrasen los tiradores de tres. Se estudian ahora las medias ponderadas de cada clúster para ver si se cumple esto y qué más información se puede obtener.

Tabla 2: Descripción mediante medias ponderadas de cada clúster. / Fuente: elaboración propia con Python y Word.

Variable	Clúster 0	Clúster 1	Clúster 2	Clúster 3
Proporción aro	0,211	0,176	0,360	0,124
Proporción cerca	0,161	0,134	0,215	0,095
Proporción media distancia	0,143	0,333	0,103	0,173
Proporción triple	0,277	0,158	0,043	0,478
Proporción tiro libre	0,209	0,199	0,279	0,130
Altura	1,978	1,985	2,066	1,965
Peso	214,411	216,846	241,240	210,250
Temporada	2018,479	2014,969	2016,776	2018,082
Acierto aro	0,657	0,645	0,688	0,642
Acierto cerca	0,417	0,425	0,432	0,405
Acierto a media distancia	0,386	0,420	0,372	0,401
Acierto triple	0,349	0,352	0,284	0,372
Acierto: tiro libre	0,781	0,809	0,666	0,807

Si se comprueban las predicciones anteriores con los datos de la tabla, se aprecia que efectivamente se cumplen. También se aprecia que, en el caso del clúster 1, formado por los jugadores que tiran más de media distancia, hay varios detalles interesantes. La variable temporada media tiene un valor considerablemente inferior que el resto, por lo que hay más casos de este clúster en las primeras temporadas que en las últimas. A su vez, su porcentaje de acierto de tres es mayor que el del clúster 0, los jugadores con perfil de tiro equilibrado. Esto nos indica que son jugadores que pueden tirar de tres, pero no lo hacen. Se aprecia también cómo, exceptuando el clúster 2, no hay diferencias en la altura y peso de los jugadores del resto de clústeres. Finalmente, se ve cómo en el clúster 3 los jugadores de media tiran un

47,8 % de sus tiros desde detrás de la línea de tres, mientras que en el caso del resto de clústeres el valor máximo de su tiro predilecto es 36 %.

Adicionalmente, se han obtenido datos del porcentaje de los jugadores de cada posición que forman cada clúster, dando lugar a la siguiente tabla:

Tabla 3: Porcentaje de los jugadores de una posición por clúster. / Fuente: elaboración propia con Python y Word.

Clúster	C	C-F	F	F-C	F-G	G	G-F
Clúster 0	10,2	16,8	37,1	18,6	31,2	34,7	31,1
Clúster 1	11,2	17,1	19,2	30,5	28,9	26,8	19,0
Clúster 2	77,3	58,6	18,4	43,1	7,8	4,5	7,0
Clúster 3	1,3	7,5	25,3	7,8	32,1	34,1	42,9

Se aprecia cómo los jugadores cuya posición principal o secundaria es *guard* (G) están divididos prácticamente de forma aleatoria en los clústeres 0, 1 y 3. En el caso de los *forwards* (F), generalmente están distribuidos de forma equilibrada entre los cuatro clústeres, habiendo menor concentración en el clúster 2 en caso de que su posición secundaria sea *guard*, o en el clúster 3 si su posición secundaria es pívot (C). En los casos de *guards* y aleros, sí que se podría hablar de que existe el concepto de baloncesto sin posiciones al haber gran variedad en los perfiles de tiro de los jugadores. Este concepto, por el contrario, no parece haber llegado a los pívots, perteneciendo tres cuartos de ellos al clúster 2 y quedando el resto distribuidos en los clústeres 0 y 1, sin apenas presencia en el clúster 3 de especialistas en triple.

Se consideró conveniente evaluar cómo ha sido la evolución del porcentaje de jugadores de la liga que cada año pertenecen a cada clúster, de donde sale el siguiente gráfico:




Ilustración 10: Evolución de la distribución de jugadores por clúster. / Fuente: elaboración propia con Python.

En él se puede apreciar cómo el clúster 1 ha disminuido drásticamente, pasando de tener más de un 40 % a representar tan solo un 9,85 %, lo que concuerda con la idea generalizada de que está desapareciendo el tiro de media distancia. Lo que rompe el esquema general es que el perfil de tiro que ha sustituido a este no ha sido el especialista en triple o clúster 3, sino el jugador con perfil de tiro equilibrado o clúster 0. El número de especialistas de 3 ha aumentado un 23,41% a un 30,79 %, pero esto tampoco representa la masiva revolución que ha habido en el juego. Finalmente, el clúster 2 de pívots ha visto su tamaño ligeramente (5 %) reducido, debido a que ha empezado a aparecer el concepto de *stretch 5*, un pívot capaz de, ocasionalmente, alejarse de la canasta y tirar desde media distancia o incluso la línea de tres.

Una vez evaluado el caso global, se dividen en tres grupos los datos, uno para cada posición principal, y se analizan por separado. En este caso se ha seleccionado un tamaño de $K=3$, al haber menor variabilidad. Adicionalmente, se ha obligado a que el clúster 0, a partir de ahora, siempre contenga a los tiradores de media distancia y el 1 a los especialistas en triples.

Tabla 4: Medias ponderadas de los clústeres de guards y aleros. Fuente: elaboración propia con Python y Word

Variable	0 Guards	0 Aleros	1 Guards	1 Aleros	2 Guards	2 Aleros
Proporción aro	0,141	0,191	0,120	0,165	0,232	0,318
Proporción cerca	0,131	0,135	0,098	0,116	0,169	0,202
Proporción media distancia	0,297	0,316	0,169	0,131	0,147	0,108
Proporción triple	0,248	0,146	0,482	0,432	0,232	0,115
Proporción tiro libre	0,184	0,212	0,130	0,156	0,219	0,258




Ilustración 11: Clústeres obtenidos en el caso de aleros y guards. / Fuente: elaboración propia con Python




Ilustración 12: Evolución de la distribución por clúster en aleros y guards. / Fuente: elaboración propia con Python.

Al estudiar estas figuras, la similitud entre *aleros* y *guards* es evidente. Si bien existen pequeñas diferencias al estudiar las medias por clúster, estas son pequeñas, realizando los aleros más tiros en el aro y los *guards* más triples. Tanto la forma global como las fronteras de los clústeres son semejantes. Finalmente, al estudiar la evolución, se aprecian patrones similares, siendo la única diferencia notable la casi desaparición del clúster de tiradores de media distancia para aleros en contraposición al pequeño resurgimiento que ha tenido en *guards*, conservando un 27% del total. Al estudiar por posiciones, queda claro que el clúster de media distancia es sustituido por el de triples. Se cree que lo ocurrido en el caso global se debe al ruido que aportaban los pivots.




Ilustración 13: Clústeres y evolución de estos obtenidos en el caso de pivots. / Fuente: elaboración propia con Python.

Los clústeres para pivots 0 y 1 siguen representando a los tiradores de media distancia y triple, respectivamente, pero el clúster 2 hace referencia al perfil de pivot tradicional que tira cerca de la canasta. Este clúster es muy compacto, tirando sus jugadores de media un 92,5 % de sus tiros en el aro, cerca de la canasta o tiros libres.

En el caso de la evolución, se ve cómo se ha mantenido el tamaño del perfil de pivot tradicional que vive en la pintura. Esto resulta sorprendente, puesto que mucha gente habla de cómo la capacidad de tiro se ha vuelto un requisito incluso en esta posición. Al igual que en el caso anterior, el clúster 1 de tiradores de triples ha ido aumentando a medida que disminuía el 0. También se aprecia que en la temporada 2020-21 ocurrió una anomalía, que hizo que no hubiera casi pivots en el clúster de media distancia.

Tras realizar el *clustering* y demostrar que ha habido una evolución, se realizan dos regresiones segmentadas para evaluar si hubo algún momento que dio lugar a una revolución y en caso de que exista, cuál fue, evaluando si es verídica la noción popular de que Stephen Curry fue el causante, y cómo se comportaban variables antes y después de dicho punto de quiebre.

Se han realizado regresiones segmentadas sobre la media de las variables proporción triple y proporción media distancia, obteniendo valores de la prueba de Davies para ambos casos menores que 0,001, por lo que se puede rechazar la hipótesis nula con evidencias altamente significativas, y tiene sentido realizar la regresión segmentada.




Ilustración 14: Regresiones segmentadas. / Fuente: elaboración propia con Python.

Se puede observar cómo entre las temporadas 2010-11 y 2021-22 existe una recta de regresión casi perfecta, siendo el R^2 de ambos modelos 0.98. El punto de quiebre lo encontramos en la temporada 2021-22, en la que disminuye considerablemente el ritmo en el que merma la proporción de tiros de media distancia y en el que la proporción de triples pasa de aumentar considerablemente temporada a temporada a estabilizarse en torno al 30 % de los tiros. Esto desmiente la idea de que Stephen Curry causó la revolución del triple; de hecho, esta revolución comenzó antes de que siquiera llegara a la liga.

Finalmente, se estudiaron datos sobre los jugadores pertenecientes al clúster de tiradores de media distancia en las temporadas 2010-11 y 2023-24. A pesar de que en la temporada 2010-11 había un total de 156 jugadores que pertenecían a este clúster, solo 21 de ellos marcaban 18 puntos por partido o más. En el caso de la temporada 2023-24, aun disponiendo solo de 40 jugadores, 24 de ellos superan dicha cantidad de puntos por partido. Estudiando el resto de los jugadores que no llegan a la barrera de 18 puntos por partido, se ve cómo entran en 3 grupos. Existe un grupo de jugadores que se encuentran por encima del percentil 75 en su eficiencia a la hora de tirar desde media distancia. Por otro lado, hay jugadores jóvenes con el

potencial para acabar siendo estrellas que deben acostumbrarse a tirarlos y, finalmente, jugadores mayores en el ocaso de su carrera que no han conseguido adaptarse.

6.2 PREDICCIÓN DE *PLAYOFFS* A PARTIR DE LA TEMPORADA REGULAR.

En el caso del modelo predictivo de la fase de *playoff* alcanzada por los equipos en base a su rendimiento en la temporada regular, se han seleccionado datos de la media de los equipos por temporada a lo largo del mismo periodo que en el caso anterior.

Se han preparado los datos traduciendo los nombres de las variables al castellano, y se ha seccionado la base de datos en dos partes: los datos de las temporadas entre 2010 y 2023 sobre los que se ha realizado el EDA y la validación cruzada anidada; y los datos de la temporada 2024, que se usaran para analizar las predicciones del modelo ante una temporada entera que no ha visto y ver que modelo se ha adaptado mejor a la evolución del juego que se ha analizado en el apartado anterior.

La base de datos de entrenamiento y validación se ha llamado `datos_temporadas` y está formada por 23 variables y 208 casos. Las variables son las siguientes:

- `temporada`: año en el que acaba la temporada.
- `equipo`: nombre del equipo.
- `fase_alcanzada`: fase de *playoffs* que alcanzó el equipo. Tiene un valor de 0 para equipos eliminados en primera ronda, 1 para semifinalistas de conferencia, 2 para finalistas de conferencia, 3 para finalistas y 4 para campeones.
- `año_temporada`: año en el que finalizó la temporada.
- `tiros_campo_ano`: promedio de los tiros de campo encestados por partido.
- `tiros_campo_intentados`: promedio de los tiros de campo lanzados por partido.
- `triples_ano`: promedio de los tiros de tres puntos encestados por partido.
- `triples_intentados`: promedio de los tiros de tres puntos lanzados por partido.
- `tiros_libres_ano`: promedio de los tiros libres encestados por partido.
- `tiros_libres_intentados`: promedio de los tiros libres lanzados por partido.
- `rebotes_ofensivos`: promedio de los rebotes en ataque obtenidos por partido.
- `rebotes_defensivos`: promedio de los rebotes en defensa obtenidos por partido.
- `rebotes_totales`: promedio de la suma de rebotes ofensivos y defensivos por partido.
- `asistencias`: promedio de asistencias dadas por partido.
- `perdidas_balón`: promedio de los balones perdidos por partido.
- `robos`: promedio de balones robados al equipo contrario por partido.
- `bloqueos`: promedio de tapones realizados a tiros del oponente por partido.
- `faltas_personales`: promedio de faltas personales cometidas por el equipo por partido.


- puntos: puntos totales anotados.
- victorias: partidos ganados en temporada regular.
- acierto_tiros_campo: porcentaje de acierto en tiros de campo.
- acierto_triples: porcentaje de acierto en tiros de tres puntos.
- acierto_tiros_libres: porcentaje de acierto en tiros libres.
- conferencia: conferencia geográfica a la que pertenece el equipo (Este u Oeste).

Sobre esta base de datos, se ha realizado un análisis exploratorio de los datos con el objetivo de conocerlos mejor y de reducir el número de variables de los modelos. Se han seleccionado las variables numéricas y se han realizado una serie de pruebas descriptivas para poder entenderlas mejor. No se han aplicado pruebas para estudiar los valores nulos debido a que no existe ninguno, y no se han estudiado los valores atípicos, al ser todos los casos reales y referentes a la temporada de un equipo. Adicionalmente, este EDA se ha realizado considerando a la variable fase alcanzada como categórica. Más adelante se explica por qué.

En el apartado descriptivo, se pudo observar cómo, por la propia naturaleza de los *playoffs*, en las fases finales existen muchos menos casos que en las primeras. Para compensar esto, se combinaron los casos de finalista y campeón. Más adelante, se han realizado ciertos ajustes que permiten asegurar que los valores con menos casos tengan más peso.

Posteriormente, se ha realizado un análisis bivariado evaluando primero la correlación entre cada variable predictora y la variable de respuesta fase alcanzada, y se ha aplicado el contraste no paramétrico Kruskal-Wallis para estudiar si existen diferencias en las variables predictoras en función de la fase de *playoffs* que alcanzan.

Tras ello, se ha hecho un análisis del factor de inflación de la varianza o VIF. Una gran cantidad de variables se pueden obtener por combinación de otras, por lo que han tenido que ser eliminadas. Este es el caso de las tres variables de tiros anotados, obteniéndose de porcentaje y número de intentos; de la variable puntos obtenida de la suma de las tres multiplicando por la puntuación de cada uno y del caso de los rebotes totales. Una vez eliminados estos casos, se obtiene la siguiente matriz de correlaciones y tabla del VIF:



Variable	VIF
Tiros campo intentados	10.0621
Rebotes defensivos	4,948
Rebotes ofensivos	3,5811
Triples intentados	3,3967
asistencias	3,1978
Acierto tiros campo	2,8742
Pérdidas balón	2,3462
victorias	2,0636
robos	1,9869
Tiros libres intentados	1,8645
Acierto triples	1,7268
Faltas personales	1,5985
Acierto tiros libres	1,4973
bloqueos	1,4199

Ilustración 15: Matriz de correlaciones y tabla de VIF / Fuente: elaboración propia con Python y Word.

La única variable en el umbral que se podría llegar a descartar es tiros de campo intentados, teniendo un valor de 10,06. Sin embargo, se decide mantenerla temporalmente para el análisis

multivariado, pero ha de obtener resultados considerablemente significativos para que se conserve.

Este análisis multivariado está formado por una regresión logística multinomial y por un análisis discriminante lineal. De esta forma no solo se obtiene información de qué variables son significativas a la hora de predecir la fase alcanzada, sino también qué variables o combinación lineal de estas separan mejor los grupos. En la siguiente tabla se indican los valores del p-valor obtenido calculando la verosimilitud del modelo completo de regresión logística multinomial y el mayor valor absoluto del coeficiente del análisis discriminante lineal:

Tabla 5: Tabla para toma de decisiones de selección de variables. / Fuente: elaboración propia con Python y Word

Variable	p-valor Regresión	Valor absoluto coeficiente LDA
victorias	0,0	0,8482
Acierto tiros campo	0,0108	0,7667
Tiros campo intentados	0,0429	1,4783
Pérdidas balón	0,0734	1,0785
Acierto tiros libres	0,0759	0,3346
Rebotes defensivos	0,1279	1,1755
Faltas personales	0,1561	0,6984
Triples intentados	0,2015	0,4394
Rebotes ofensivos	0,2941	1,1647
Robos	0,4485	0,6076
Tiros libres intentados	0,457	0,256
Asistencias	0,5682	0,4852
Acierto triples	0,7919	0,2915
Bloqueos	0,9691	0,25

Se han seguido dos criterios para elegir qué variables se deben eliminar. Estos son: que el p-valor para la regresión logística multinomial sea mayor que 0,25 y que el mayor valor absoluto del LDA no supere 0,4. Esto solo lo cumplen las variables bloqueos, acierto triples y tiros libres intentados. En el caso de la variable tiros de campo intentados, que antes tenía valores elevados del VIF, se observa que no solo es significativa, con un p-valor de 0,0429 para la regresión, sino que obtiene el valor absoluto máximo en el LDA, por lo que se ha decidido conservarla. Al realizar otro análisis VIF con estas once variables, el valor VIF de la variable tiros de campo intentados desciende hasta 9.48.

Nuestra variable de respuesta presenta un caso bastante peculiar. La fase alcanzada por los equipos sigue un orden jerárquico; sin embargo, al estudiar los datos, se encontraron evidencias para pensar que no cumple el supuesto de ratios proporcionales. Para comprobar esto, se ha estudiado el perfil de coeficientes de las variables que, según el EDA, deberían ser más discriminantes, obteniendo el siguiente gráfico:




Ilustración 16: Estudio de los coeficientes beta según el cruce de las fases. Fuente: elaboración propia con Python

Se aprecia claramente cómo las pendientes de las rectas varían considerablemente, lo que confirma la teoría de que se incumple el supuesto de ratios proporcionales. Esto justifica que se aplique un *test* de razón de verosimilitud o LRT para estudiar si merece la pena usar un modelo restringido, es decir, mantener fase alcanzada como variable ordinal; o si, por el contrario, se debe usar un modelo no restringido, pasando a considerarla como categórica. El p-valor de dicha prueba es de 0,031, por lo que se han encontrado evidencias significativas de que se debe empezar a tratar la variable fase alcanzada como categórica.

De esta forma, se ha reducido nuestra base de datos a once variables predictoras, con la seguridad de saber que todas las variables predictoras deberían contribuir al modelo, que solo la variable tiros de campo intentados podría dar problemas con la multicolinealidad; y a una variable de respuesta que se trata como categórica con cuatro clases.

Con esto explicado, se pasa a la fase de validación cruzada anidada, donde se han entrenado y validado un total de nueve modelos de aprendizaje automático supervisado. En concreto, son regresión logística multinomial, árbol de decisión, *K* vecinos más cercanos, máquinas de vectores de soporte, *Naive Bayes*, *Random Forest*, *AdaBoost*, *XGBoost* y *LightGBM*.

Se ha seleccionado como métrica objetivo el *F1-Score-Macro*, ya que permite corregir el problema de desbalanceo de casos en la variable objetivo. Esta métrica calcula el *F1-Score* de cada clase de la variable de respuesta y luego hace la media de estas. Los equipos eliminados en primera ronda eran los casos más fáciles de predecir y al ser la mitad de las observaciones, daría lugar a un sesgo enorme en caso de utilizar otras métricas.

Debido a que la base de datos está formada por tan solo 208 casos, se ha decidido prescindir de la partición *train/test* tradicional y la validación cruzada anidada utiliza todo el conjunto de datos. También, en los modelos que lo permiten, se añade una penalización mayor a los errores de fases avanzadas, siendo esta penalización inversamente proporcional a la distribución de las fases.

Se ha usado en la validación cruzada anidada una estructura formada por un bucle externo con cinco particiones y un bucle interno de tres, es decir, para cada combinación de hiperparámetros se entrenan y validan quince modelos. Los modelos de aprendizaje conjunto por pura naturaleza son los que acaban realizando más entrenamientos y validaciones. En total, se han realizado 3150 validaciones y entrenamientos. En cuanto a los resultados obtenidos por todas estas validaciones y entrenamientos, vienen dados en las siguientes figuras:




Ilustración 17: Box plot con el rango de los resultados de cada modelo / Fuente: elaboración propia con Python y Word

Tabla 6: Métricas de evaluación de los modelos. / Fuente: elaboración propia con Python y Word

Modelo	Media F1-Score Macro	Mediana F1-Score Macro	Limite inf. F1-Score Macro	Limite sup F1-Score Macro	ROC-AUC OVR	MAE
Random Forest	0.4296	0.4039	0.3066	0.5526	0.7089	0.6961
LightGBM	0.4221	0.3806	0.3169	0.5273	0.6978	0.7494
XGBoost	0.4166	0.4205	0.3171	0.5161	0.7032	0.6528
AdaBoost	0.4155	0.4149	0.331	0.4999	0.6812	0.6578
Logistic Regression	0.3844	0.3527	0.2695	0.4993	0.6837	0.7882
SVC (SVM)	0.3725	0.3812	0.2961	0.449	0.6988	0.7837
Naive Bayes	0.3681	0.3458	0.3054	0.4307	0.6626	0.7836
Decision Tree	0.3616	0.3143	0.2016	0.5216	0.6047	0.821
K-Nearest Neighbors	0.3182	0.3078	0.2533	0.3832	0.6366	0.7597

Es evidente que los modelos de *ensemble* destacan por encima del resto con puntuaciones superiores. *Random Forest* obtiene las mejores puntuaciones de media del *F1-Score Macro* y de ROC-AUC-OVR, pero también presenta mucha variabilidad, al tener los intervalos de confianza más amplios. *XGBoost* también parece un gran candidato, al tener las mejores puntuaciones de la mediana del *F1-Score Macro* y un MAE de 0,6528. Estudiando la tabla a nivel general, se ve cómo se obtienen puntuaciones a priori bajas para el *F1-Score Macro*; sin embargo, cumplen con los criterios de Provost y Fawcett expuestos anteriormente, por lo que sí que se pueden considerar estas puntuaciones como correctas y superan con creces al estimador aleatorio que tendría un valor esperado de 0,17.

Después de entrenar y evaluar los modelos, se pasa a comprobar cómo se comportan ante los datos de la temporada 2023-24 que el modelo desconoce. Para realizar este procedimiento se han seleccionado los hiperparámetros más comunes de cada uno de los modelos anteriormente entrenados y se han realizado las predicciones.

Se han añadido un par de procedimientos a este apartado para mejorar la calidad de dichas predicciones. Para empezar, se dividen los datos en este y oeste de forma que los modelos deben predecirlos por separado. Cada modelo da una probabilidad a cada fase y se multiplica dicha probabilidad por el valor de la fase, dando lugar a una puntuación entre 0 y 3. Los equipos de cada conferencia con mayor puntuación reciben el valor de finalista; el siguiente, finalista de conferencia; los dos siguientes, semifinalistas de conferencia; y los cuatro últimos, primera ronda. De esta forma se asegura que las predicciones tengan la estructura real.

También se ha creado una medida de precisión personalizada. Si el modelo acierta, suma un punto; si falla por una fase, suma medio punto; si lo hace por dos fases, resta medio punto y un punto en caso de fallo por tres fases; y finalmente, se hace la media de todos. De esta forma se premian los casos donde el modelo se acerca, y se penalizan en los que falla considerablemente. A continuación, se expresa dicha precisión junto con el número de aciertos y fallos.

Tabla 7: Aciertos, fallos y puntuación personalizada de cada modelo. / Fuente: elaboración propia con Python y Word

Modelo	Aciertos	Fallos por 1	Fallos por 2	Fallos por 3	Precisión Personalizada
Random Forest	11	3	1	1	0,6875
K-Nearest Neighbors	10	4	0	2	0,625
XGBoost	7	7	1	1	0,5625
AdaBoost	8	5	2	1	0,53125
SVC (SVM)	6	7	2	1	0,46875
Naive Bayes	5	8	1	2	0,40625
Logistic Regression	6	6	2	2	0,375
LightGBM	6	6	2	2	0,375
Decision Tree	5	6	3	2	0,28125

Observando esta tabla, queda claro que el modelo que mejor se ha adaptado es *Random Forest*, al igual que lo que se observaba al realizar la validación cruzada. El resto de los modelos de *ensemble* obtienen resultados notablemente inferiores. Se cree que esto se debe al pequeño tamaño de muestra, que ha causado que los modelos de *boosting* sufran de *overfitting*. El modelo de K vecinos más cercanos también obtiene unas predicciones bastante aceptables, pero teniendo en cuenta sus pésimas puntuaciones en las evaluaciones de la validación cruzada, no sería recomendable usarlo.

Para estudiar mejor el comportamiento de *Random Forest*, se analizaron los dos casos donde el modelo falla por más de una fase. A continuación, se explica el porqué de estos fallos.

Que los *Dallas Mavericks* llegaran a la final fue una sorpresa mayúscula que no pudo ser anticipada por ninguno de los modelos, ni por los expertos antes. El otro error se corresponde a *Oklahoma City Thunder* y se cree que se debe a una variable que no se ha evaluado, la experiencia. Este equipo tenía la edad media más baja con diferencia, en concreto, de 23,17 años, teniendo una diferencia de 1,4 años con el siguiente equipo y de 2,47 si solo se seleccionan aquellos equipos que pasaron de la primera fase. Adicionalmente, esta era la primera vez que la mayoría de sus jugadores habían conseguido pasar de la primera fase. Debido a esto, no pudieron mantener el nivel de la fase regular a la fase de *playoffs*, cayendo prematuramente. Ambos casos son errores que un humano podría cometer por lo que se respalda la hipótesis de que el modelo entiende qué hace que un equipo vaya a alcanzar cierta fase.

ESPN da cada año la opción a los usuarios de predecir los *playoffs*, haciendo que elijan qué equipo creen que avanzaría en la primera ronda. Este proceso se repitió para cada ronda hasta obtener una predicción de todo el cuadro de *playoffs*. De esta forma, el consenso del público realizó la siguiente predicción sobre la fase alcanzada por los equipos de la NBA en la temporada 2023-24.




Ilustración 18: Predicciones realizadas por seres humanos en la temporada 2023-24. / Fuente: ESPN (2024)

En dicha predicción, los usuarios tenían en cuenta la racha final de los equipos, los enfrentamientos directos y la situación de lesiones; información de la que los modelos no disponen. A pesar de eso, obtuvieron diez aciertos, dos fallos por una fase y cuatro fallos por dos fases. Esto supone una puntuación personalizada de 0,5625 considerablemente inferior a la del modelo de *Random Forest*.

7. CONCLUSIONES

Tras haber finalizado el caso práctico, creo que he conseguido cumplir con todos los objetivos que definí anteriormente, obteniendo las siguientes conclusiones.

- Se han podido crear clústeres muy claros en función de los perfiles de tiro de los jugadores, pudiendo diferenciarlos claramente. Tanto de forma general como posición a posición, está desapareciendo el perfil de jugador cuyo tiro predilecto es el de media distancia, siendo sustituido por tiradores equilibrados o especialistas en triples. Adicionalmente, para el caso de *guards* y aleros, se ha comprobado cómo los perfiles de tiro presentan grandes similitudes, lo que sugiere que, en términos de perfiles de tiro, es correcto hablar de baloncesto sin posiciones.
- Se ha comprobado que existe un punto de inflexión; sin embargo, no de la forma que se había planteado. Las variables de proporción de triple y de media distancia han sufrido un cambio estable entre las temporadas 2010-2011 y 2021-22. La causa de este aumento estable y el momento que causaron este crecimiento en el que se ha duplicado el número de triples preceden a la base de datos. El punto de inflexión obtenido se encuentra en la temporada 2021-22, donde se han estabilizado ambas variables.
- Gracias a la validación cruzada anidada, se han podido diseñar varios modelos predictivos de aprendizaje automático, siendo *Random Forest* el mejor de ellos. Dicho modelo no solo ha obtenido unos parámetros y clasificaciones muy aceptables, sino que, en el caso de la temporada 2023-24, ha superado las predicciones realizadas por humanos. Adicionalmente, se han visto los problemas que tienen los modelos de *boosting* con bases de datos pequeñas.

Al realizar la selección de variables sobre el conjunto de datos total y no incluirlo en el bucle externo, el modelo sufre de un ligero *data leakage* y las métricas tendrán un sesgo de optimismo. Como línea de trabajo futuro convendría corregir esto. También creo que añadir variables como la edad media, el resultado de playoffs del año anterior y la proporción de victorias después del *All-Star* mejoraría la capacidad clasificadora de los modelos.

Una conclusión personal, que no ha sido verificada mediante análisis estadístico, es que, independientemente de la cantidad de datos de los que hubiera dispuesto, nunca habría podido obtener un buen modelo de *boosting*. La evolución del baloncesto es un proceso rápido y constante, cómo se ha podido observar en el primer apartado del caso práctico, por lo que, a medida que se añaden más datos, aumenta también la variabilidad de estos. Aun si se seleccionaran todos los casos de una temporada, incluidos los de los equipos que no pasaron a la fase de *playoffs*, se necesitarían 33 años para alcanzar las mil observaciones. Esto crea una paradoja donde se necesita más información, pero esa información hace que el modelo sea peor.

En lo personal, este trabajo me ha servido para poder mejorar mis conocimientos sobre *machine learning*. Ha sido mi primer contacto con la validación cruzada anidada y me ha parecido una técnica no solo útil, sino necesaria en una gran cantidad de casos.

Finalmente, me gustaría citar a Daryl Morey:

“La única forma sostenible de ir un paso por delante de tus rivales es teniendo una ventaja analítica.”

8. BIBLIOGRAFÍA

- Ayyildiz, E. (2018). Estimation of American Basketball League (NBA) Match Results by Artificial Neural Networks. *Gaziantep University Journal of Sports Science*, 3(1), 40-53.
- Bhandari, I., Colet, E., Parker, J., Pines, Z., Pratap, R. y Ramanujam, K. (1997). Advanced Scout: Data Mining and Knowledge Discovery in NBA Data. *Data Mining and Knowledge Discovery*, 1(1), 121-125. <https://doi.org/10.1023/A:1009782106822>
- CBS Sports (2023). *How MIT's Sloan Conference became the epicenter of the sports analytics movement*. <https://www.cbssports.com/nba/news/how-mits-sloan-conference-became-the-epicenter-of-the-sports-analytics-movement/>
- Džeroski, S. y Ženko, B. (2004). Is Combining Classifiers with Stacking Better than Selecting the Best One? *Machine Learning*, 54(3), 255-273. <https://doi.org/10.1023/B:MACH.0000015881.36452.6e>
- ESPN. (2024). *NBA Playoff Challenge 2024: People's Bracket*. <https://fantasy.espn.com/games/nba-playoff-challenge-2024/peoplesbracket>
- Goldsberry, K. (2019). *Sprawlball: A Visual Tour of the New Era of the NBA*. Houghton Mifflin Harcourt.
- Goldsberry, K. (2024). *Hoop Atlas: Mapping the Remarkable Transformation of the Modern NBA*. Mariner Books.
- Hastie, T., Tibshirani, R. y Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2.^a ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- He, G. y Choi, H. S. (2025). Stacked ensemble model for NBA game outcome prediction analysis. *Scientific Reports*, 15(1), 29983. <https://doi.org/10.1038/s41598-025-13657-1>
- Infanti, A., Starcevic, V., Schimmenti, A., Khazaal, Y., Karila, L., Giardina, A., Flayelle, M., Hedayatzadeh Razavi, S. B., Baggio, S., Vögele, C. y Billieux, J. (2023). Predictors of Cyberchondria During the COVID-19 Pandemic: Cross-sectional Study Using Supervised Machine Learning. *JMIR Formative Research*, 7, e42206. <https://doi.org/10.2196/42206>

- Irizarry, R. A. (2019). Validación cruzada. En *Introducción a la ciencia de datos: Análisis de datos y algoritmos de predicción con R*. <https://rafalab.github.io/dslibro/cross-validation.html>
- James, G., Witten, D., Hastie, T. y Tibshirani, R. (2023). *An Introduction to Statistical Learning: with Applications in Python*. Springer.
- Kassambara, A. (2024, 7 de febrero). *Visualización de datos con Seaborn*. Datanovia. <https://www.datanovia.com/es/learn/programming/python/data-science/data-visualization-with-seaborn.html>
- Lau, S., Gonzalez, J. y Nolan, D. (2023). Model Selection: Train-Test Split. En *Learning Data Science: Data Wrangling, Exploration, Visualization, and Modeling with Python*. O'Reilly Media. https://learningds.org/ch/16/ms_train_test.html
- Little, R. J. A., y Rubin, D. B. (2019). *Statistical Analysis with Missing Data* (3rd ed.). John Wiley & Sons. <https://doi.org/10.1002/9781119482260>
- McFarlane, P. (2019). Evaluating NBA end-of-game decision-making. *Journal of Sports Analytics*, 5(1), 17-22. <https://doi.org/10.3233/JSA-180231>
- National Basketball Association. (2025). Official Rules of the National Basketball Association 2025-2026. <https://ak-static.cms.nba.com/wp-content/uploads/sites/4/2025/10/Official-2025-26-NBA-Playing-Rules.pdf>
- NBAPlayoffPass. (2026). *NBA Playoff Bracket*. <https://nbaplayoffpass.com/bracket/>
- Oughali, M. S., Bahloul, M. y El Rahman, S. A. (2019). Analysis of NBA Players and Shot Prediction Using Random Forest and XGBoost Models. En *2019 International Conference on Computer and Information Sciences (ICCIS)* (pp. 1-5). IEEE. <https://doi.org/10.1109/ICCISci.2019.8716412>
- Provost, F. y Fawcett, T. (2013). *Data Science for Business: What You Need to Know About Data Mining and Data-Analytic Thinking*. O'Reilly Media. <https://learning.oreilly.com/library/view/data-science-for/9781449374273/>
- Pu, H. (2016). Mediating the giants: Yao Ming, NBA and the cultural politics of Sino-American relations. *Asia Pacific Journal of Sport and Social Science*, 5(2), 87-107. <https://doi.org/10.1080/21640599.2016.1191703>
- South, C. (2025). A basketball paradox: exploring NBA team defensive efficiency in a positionless game. *Journal of Quantitative Analysis in Sports*, 21(4), 345-359. <https://doi.org/10.1515/jqas-2024-0010>
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley Publishing Company.

- Wang, H., Sarker, A. y Hosoi, A. (2025). The Effect of Basketball Analytics Investment on National Basketball Association (NBA) Team Performance. *Journal of Sports Economics*, 26(6), 668-688. <https://doi.org/10.1177/15270025251328264>
- Yerra, B. (2018, 19 de febrero). *Centroid-based Clustering K-Means Algorithm*. Bhanu Yerra's Blog. <https://mlbhanuyerra.github.io/2018-02-19-Clustering-K-means/>
- Zhou, Z. H. (2021). *Machine Learning*. Springer Nature. <https://doi.org/10.1007/978-981-15-1967-3>